

LAPORAN PRAKTIKUM

WEB SCRAPING, INTEGRASI DATA, DAN ANALISIS EKSPLORASI (EDA) FAKTOR PENDORONG HAPPINESS SCORE NEGARA-NEGARA DUNIA

Aziz Rahmad Arifin 5054251002

Studi Kasus: Data Populasi, Geografi, dan World Happiness Report 2025

1. Pendahuluan

Praktikum ini dikerjakan dalam dua tahap yang saling berkesinambungan. Tahap pertama berfokus pada pengumpulan data melalui teknik web scraping dari beberapa sumber terbuka di internet, yaitu Worldometers untuk data negara dan luas wilayah, Our World in Data untuk data populasi historis beserta proyeksi PBB, dan World Happiness Report (WHR) 2025 untuk data skor kebahagiaan beserta variabel-variabel penjelasnya. Ketiga sumber tersebut kemudian dibersihkan, disatukan (merge), dan disimpan dalam satu berkas dataset gabungan berformat CSV bernama `dataset_country_population_happiness.csv`. Tahap kedua memanfaatkan dataset hasil scraping tersebut untuk melakukan analisis eksplorasi data (Exploratory Data Analysis/EDA) guna memahami pola, distribusi, dan hubungan antara Happiness Score dengan variabel-variabel penjelasnya.

Latar belakang praktikum ini didasari oleh kebutuhan untuk memahami faktor-faktor apa saja yang berhubungan dengan tingkat kebahagiaan suatu negara, serta bagaimana proses pengumpulan data mentah dari berbagai sumber web yang berbeda struktur dapat disatukan menjadi satu dataset analitis yang konsisten. Permasalahan yang dihadapi meliputi perbedaan format dan penamaan negara antar sumber data (misalnya "Czechia" pada satu sumber versus "Czechia (Czech Republic)" pada sumber lain), rentang tahun yang tidak selalu sama, serta banyaknya nilai kosong (missing value) akibat cakupan data yang berbeda-beda antar sumber.

Tujuan dari praktikum ini adalah: (1) mempraktikkan teknik web scraping menggunakan pustaka `requests` dan `BeautifulSoup` untuk mengambil data tabel dari halaman HTML serta mengunduh berkas data langsung dari tautan yang ditemukan pada suatu halaman web; (2) melakukan proses pembersihan, standardisasi, dan penggabungan (merge) data dari tiga sumber berbeda menjadi satu dataset panel negara-tahun; dan (3) melakukan EDA menyeluruh terhadap dataset hasil scraping untuk mengidentifikasi variabel yang paling berhubungan dengan Happiness Score, termasuk melihat pola distribusi, korelasi, tren waktu, perbedaan antar-benua, serta memeriksa potensi multikolinearitas antar variabel penjelas.

Secara umum, alur eksperimen yang dilakukan adalah sebagai berikut: scraping tabel daftar negara dan luas wilayah dari Worldometers → scraping/unduh data populasi dari Our World in Data → scraping tautan unduhan data Figure 2.1 dari situs World Happiness Report lalu mengunduh berkas Excel-nya → pembersihan dan pencocokan nama negara antar ketiga sumber → penggabungan (merge) menjadi dataset akhir → ekspor ke CSV → EDA univariat, bivariat, per waktu, per benua, hingga pemeriksaan multikolinearitas (VIF) dan regresi OLS sebagai alat bantu eksplorasi.

2. Dasar Teori

2.1 Web Scraping

Web scraping merupakan teknik pengambilan data secara otomatis dari halaman web dengan cara mengunduh konten HTML suatu laman kemudian mengekstraksi informasi yang dibutuhkan dari struktur tag HTML tersebut. Pada praktikum ini, proses scraping dilakukan menggunakan pustaka requests untuk mengirimkan permintaan HTTP ke server web dan mengambil respons berupa teks HTML, serta pustaka BeautifulSoup untuk mem-parsing (mengurai) teks HTML tersebut menjadi struktur objek yang dapat ditelusuri, misalnya untuk mencari seluruh elemen tabel (<table>) atau seluruh tautan (<a>) pada suatu halaman.

Penggunaan header HTTP berupa User-Agent pada setiap permintaan dimaksudkan agar permintaan yang dikirim menyerupai permintaan dari browser sungguhan, sehingga mengurangi kemungkinan permintaan ditolak oleh server. Status code HTTP (misalnya 200 untuk berhasil) digunakan sebagai indikator apakah halaman berhasil diakses sebelum data diproses lebih lanjut.

2.2 Integrasi dan Pembersihan Data (Data Wrangling)

Data yang berasal dari sumber berbeda umumnya memiliki format, satuan, dan penamaan entitas yang tidak seragam. Proses data wrangling mencakup penggantian nama kolom (rename), konversi tipe data (misalnya string yang mengandung tanda koma ribuan diubah menjadi tipe numerik), penanganan nilai yang hilang, serta pemetaan (mapping) nama entitas yang berbeda penyebutan namun merujuk pada entitas yang sama, seperti pemetaan nama negara "Czechia" menjadi "Czechia (Czech Republic)" agar dapat dicocokkan antar dataset. Proses penggabungan (merge) antar dataset dilakukan berdasarkan kunci gabungan (composite key) berupa kombinasi nama negara dan tahun.

2.3 Analisis Eksplorasi Data (EDA)

EDA adalah tahap analisis awal terhadap suatu dataset yang bertujuan memahami karakteristik data sebelum masuk ke pemodelan lebih lanjut. EDA yang dilakukan pada praktikum ini mencakup analisis univariat (melihat distribusi tiap variabel menggunakan histogram dan boxplot), analisis bivariat (melihat hubungan antar dua variabel menggunakan matriks korelasi dan scatter plot dengan garis regresi), serta analisis berdasarkan dimensi waktu dan kategori (tren tahunan dan perbandingan antar-benua).

2.4 Variance Inflation Factor (VIF) dan Regresi OLS

Variance Inflation Factor (VIF) digunakan untuk mendeteksi multikolinearitas, yaitu kondisi ketika satu variabel penjelas memiliki hubungan linear yang kuat dengan variabel penjelas lainnya. Nilai VIF yang

jauh di bawah ambang batas umum (5 atau 10) menandakan tidak ada masalah multikolinearitas yang serius. Regresi Ordinary Least Squares (OLS) pada praktikum ini tidak digunakan sebagai model prediktif final, melainkan sebagai alat bantu eksplorasi untuk melihat arah dan kekuatan hubungan setiap variabel driver terhadap Happiness Score ketika variabel lain dikontrol (held constant), dengan standard error yang bersifat heteroscedasticity-robust (HC3) agar estimasi tetap valid meski terdapat ketidaksamaan varians pada residual.

3. Metodologi / Prosedur Praktikum

3.1 Tools dan Library

Praktikum ini menggunakan bahasa pemrograman Python pada lingkungan Google Colab/Jupyter Notebook, dengan pustaka utama sebagai berikut: requests dan BeautifulSoup4 untuk web scraping; pandas untuk manipulasi data tabular; country_converter untuk konversi nama negara ke benua; openpyxl untuk membaca berkas Excel; matplotlib dan seaborn untuk visualisasi data; serta statsmodels untuk perhitungan VIF dan regresi OLS pada notebook EDA.

3.2 Tahap Pengumpulan Data (Web Scraping)

3.2.1 Data Negara dan Luas Wilayah (Worldometers)

Data negara diambil dari halaman "Alphabetical List of Countries" pada situs Worldometers menggunakan permintaan GET dengan header User-Agent khusus. Permintaan tersebut berhasil dengan status code 200. Halaman HTML kemudian diurai dengan BeautifulSoup, dan ditemukan satu tabel pada halaman tersebut dengan kolom #, Country, Population 2026, Land Area (Km²), dan Density (P/Km²) — kolom luas wilayah dan kepadatan pada HTML asli mengandung karakter yang salah encoding (Km^Â²) sehingga dilakukan rename menjadi Km² yang benar. Tabel diekstraksi baris per baris menjadi list, kemudian dikonversi menjadi DataFrame berukuran 195 baris (setelah baris header dipisahkan) dengan 195 negara unik.

Kolom numerik (Population 2026, Land Area (Km²), Density (P/Km²)) yang semula bertipe teks dan mengandung tanda koma pemisah ribuan dibersihkan dengan menghapus koma dan mengganti karakter minus non-standar (–) menjadi tanda minus biasa, lalu dikonversi ke tipe numerik menggunakan `pd.to_numeric`. Kolom benua (Continent) ditambahkan menggunakan fungsi `coco.convert()` dari pustaka `country_converter`, yang memetakan nama negara ke benuanya secara otomatis.

3.2.2 Data Populasi (Our World in Data)

Data populasi historis dan proyeksi diunduh langsung dalam format CSV dari Our World in Data (grafik population-with-un-projections), menghasilkan 39.562 baris data mencakup 262 negara/entitas. Kolom populasi hasil estimasi (population__sex_all__age_all__variant_estimates) digabungkan dengan kolom proyeksi median (...variant_medium__projected) menggunakan fillna, sehingga terbentuk satu kolom Population yang mencakup data historis maupun proyeksi hingga tahun 2100. Kolom entity dan year masing-masing diganti nama menjadi Country dan Year.

Untuk mencocokkan penamaan negara antar dua sumber data, dilakukan pemetaan manual (country_mapping) terhadap 12 nama negara yang berbeda penyebutan, misalnya "Cape Verde" → "Cabo Verde", "Czechia" → "Czechia (Czech Republic)", "East Timor" → "Timor-Leste", dan "United States" → "United States of America". Setelah pemetaan diterapkan dua kali (termasuk penambahan pemetaan untuk "Congo"), seluruh 195 negara pada data pertama berhasil ditemukan padanannya pada data populasi, sehingga tidak ada lagi negara yang belum cocok (unmatched = 0).

Data populasi kemudian digabungkan dengan informasi luas wilayah dan benua dari data negara, lalu kepadatan penduduk dihitung ulang (Population / Land Area) untuk setiap tahun agar konsisten dengan data populasi historis (bukan hanya kepadatan tahun 2026 seperti pada data mentah Worldometers). Dataset populasi ini kemudian difilter agar hanya mencakup tahun 2011 ke atas, menghasilkan 17.550 baris data (195 negara × 90 tahun, 2011–2100), yang mencakup rentang historis maupun proyeksi jangka panjang.

3.2.3 Data Happiness Score (World Happiness Report 2025)

Halaman resmi World Happiness Report 2025 diakses dan diurai untuk mencari tautan unduhan data, khususnya tautan berteks "data for figure 2.1". Tautan yang ditemukan (https://files.worldhappiness.report/WHR25_Data_Figure_2.1v3.xlsx) kemudian diunduh langsung sebagai berkas Excel (149.058 byte) dan dibaca menggunakan pandas. Berkas ini berisi 1.969 baris mencakup rentang tahun 2011–2024 dengan 13 kolom, meliputi Rank, Country name, Life evaluation (3-year average), serta enam variabel penjelas ("Explained by...") dan komponen Dystopia + residual.

Kolom-kolom tersebut kemudian di-rename agar lebih ringkas dan konsisten dengan dataset lain, yaitu Rank → Happiness Rank, Country name → Country, Life evaluation (3-year average) → Happiness Score, serta keenam variabel "Explained by..." masing-masing menjadi GDP_per_Capita, Social_Support, Healthy_Life_Expectancy, Freedom, Generosity, dan Perceptions_of_Corruption.

Proses pencocokan nama negara antara data Happiness dan data negara pertama menemukan 21 nama yang belum cocok, seperti "Czechia", "DR Congo", "Republic of Korea", "Türkiye", dan "Viet Nam". Pemetaan tambahan (happiness_mapping) diterapkan untuk menyelaraskan nama-nama

tersebut; beberapa entitas yang memang bukan negara berdaulat dalam data Worldometers (seperti Hong Kong SAR of China, Kosovo, North Cyprus, Puerto Rico, dan Somaliland Region) sengaja dipetakan ke None dan baris-barisnya dihapus dari data Happiness karena tidak memiliki padanan pada data negara utama. Setelah pemetaan, seluruh negara pada data Happiness berhasil dicocokkan (unmatched = 0), sementara tercatat 34 negara pada data utama yang memang tidak memiliki data Happiness sama sekali (umumnya negara berukuran kecil seperti negara-negara kepulauan Pasifik, Andorra, Monaco, dan Liechtenstein).

3.3 Penggabungan Dataset dan Validasi

Ketiga sumber data digabungkan melalui proses merge berdasarkan kombinasi kunci Country dan Year, dengan tipe left join dari data populasi ke data Happiness agar seluruh baris populasi tetap dipertahankan meskipun tidak memiliki data Happiness pada tahun tertentu. Sebelum penggabungan final, dilakukan beberapa iterasi validasi: dataset dibatasi ulang ke rentang tahun 2011–2024 (menyesuaikan cakupan data Happiness, bukan proyeksi populasi hingga 2100), diperiksa jumlah baris yang memiliki nilai Happiness Score terisi per tahun, serta diperiksa ada tidaknya baris duplikat berdasarkan kombinasi Country dan Year.

Hasil akhir tahap scraping/integrasi ini menghasilkan dua bentuk dataset: dataset utama (final_df) berisi 17.550 baris mencakup 195 negara pada rentang tahun 2011–2100 (termasuk baris proyeksi populasi yang tidak memiliki data Happiness), dan subset khusus (happiness_analysis) berisi 1.915 baris dari 161 negara pada rentang 2011–2024 yang memiliki data Happiness Score terisi. Dataset utama inilah yang kemudian diekspor menjadi dataset_country_population_happiness.csv, dengan validasi akhir menunjukkan 195 negara unik, rentang tahun 2011–2100, dan total 17.550 baris.

3.4 Tahap Analisis Eksplorasi Data (EDA)

Notebook EDA memuat dataset_country_population_happiness.csv hasil scraping sebagai titik awal, kemudian melakukan serangkaian tahap sebagai berikut: (1) pemeriksaan struktur dan ringkasan missing value per kolom; (2) pembersihan data dengan memfilter baris yang memiliki Happiness Score terisi pada rentang tahun 2011–2024, serta menangani nilai tak terhingga (inf) pada kolom kepadatan penduduk yang muncul akibat pembagian oleh luas wilayah yang bernilai nol (misalnya untuk entitas Holy See/Vatikan); (3) pemeriksaan ketersediaan variabel driver (GDP_per_Capita, Social_Support, dan lainnya) per tahun, yang ditemukan hanya tersedia lengkap pada rentang 2019–2024; (4) EDA univariat berupa histogram dan boxplot; (5) EDA bivariat berupa matriks korelasi, scatter plot dengan garis regresi, dan pairplot; (6) EDA berdasarkan waktu dan benua; serta (7) pemeriksaan multikolinearitas menggunakan VIF dan regresi OLS sebagai alat bantu eksplorasi tambahan.

Dua subset data disiapkan untuk kebutuhan berbeda: `long_data` yang mencakup seluruh baris 2011–2024 (untuk melihat tren jangka panjang Happiness Score, meskipun variabel driver belum lengkap pada tahun-tahun awal), dan `eda_data` yang dibatasi hanya pada tahun 2019–2024 serta baris yang memiliki seluruh variabel driver terisi (untuk analisis hubungan antar-variabel), menghasilkan 847 baris dari 151 negara.

4. Hasil dan Pembahasan

4.1 Hasil Tahap Scraping dan Integrasi Data

Tabel berikut merangkum ukuran dataset pada tiap tahap scraping dan integrasi, mulai dari sumber data mentah hingga dataset gabungan akhir.


Tahap / Dataset	Jumlah Baris	Jumlah Negara/Entitas	Cakupan Tahun
Data negara (Worldometers)	195	195	— (snapshot 2026)
Data populasi mentah (Our World in Data)	39.562	262	1950 – 2100
Data populasi setelah filter tahun ≥ 2011 & join negara	17.550	195	2011 – 2100
Data Happiness mentah (WHR 2025, Figure 2.1)	1.969	≈ 161 (setelah cleaning)	2011 – 2024
Dataset akhir (<code>final_df</code> / CSV hasil ekspor)	17.550	195	2011 – 2100
Subset dengan Happiness Score terisi	1.915	161	2011 – 2024

Perbedaan cakupan negara antar sumber terlihat jelas dari hasil pencocokan nama: seluruh 195 negara pada data Worldometers berhasil dicocokkan dengan data populasi Our World in Data setelah pemetaan nama diterapkan, sedangkan hanya 161 dari 195 negara yang memiliki data Happiness Score, karena World Happiness Report memang tidak mencakup seluruh negara di dunia — terutama negara berukuran kecil seperti negara kepulauan Pasifik, Andorra, Monaco, dan Liechtenstein sebanyak 34 negara. Hal ini konsisten dan wajar mengingat WHR mensyaratkan ketersediaan survei Gallup World Poll di negara bersangkutan.

Tidak ditemukan baris duplikat pada kombinasi Country dan Year di dataset akhir (Duplicate Country + Year: 0), yang menandakan proses merge berjalan sesuai rencana tanpa menghasilkan baris ganda. Pemeriksaan pada satu negara sampel (Jepang) menunjukkan bahwa untuk tahun-tahun tanpa data Happiness (di luar 2011–2024, misalnya proyeksi setelah 2024), kolom Happiness Score memang kosong (NaN), sesuai ekspektasi bahwa data Happiness hanya tersedia pada rentang tahun aktual survei.

4.2 Kualitas Data dan Missing Value pada Tahap EDA

Pemeriksaan awal pada notebook EDA terhadap dataset_country_population_happiness.csv (17.550 baris, 17 kolom) menunjukkan bahwa kolom-kolom dasar seperti Country, Continent, Year, Population, dan Land Area (Km²) tidak memiliki missing value sama sekali (0%). Sebaliknya, kolom Happiness Score dan Happiness Rank memiliki missing value sebesar 89,1% (15.635 dari 17.550 baris), sedangkan kolom-kolom variabel driver (Freedom, Social_Support, Dystopia_Residual, Generosity, Perceptions_of_Corruption, GDP_per_Capita, Healthy_Life_Expectancy) serta Upper/Lower whisker memiliki missing value sekitar 95,1–95,2%.




Gambar 1. Persentase missing value per kolom pada dataset mentah. Kolom geografis/populasi lengkap (0% missing), sedangkan kolom terkait Happiness memiliki missing value tinggi karena dataset mencakup proyeksi populasi hingga tahun 2100 yang jauh melampaui cakupan tahun WHR (2011–2024).

Tingginya persentase missing value ini bukan menandakan kualitas scraping yang buruk, melainkan konsekuensi logis dari desain dataset gabungan yang mencakup proyeksi populasi hingga tahun 2100, sementara data Happiness Score hanya tersedia untuk tahun 2011–2024. Setelah data difilter hanya pada baris dengan Happiness Score terisi dan rentang tahun 2011–2024, dataset menyusut menjadi 1.915 baris dari 161 negara, tanpa baris duplikat (Country, Year). Pemeriksaan lebih lanjut terhadap ketersediaan variabel driver per tahun mengonfirmasi bahwa driver-driver tersebut (GDP_per_Capita, Social_Support, dan lainnya) baru terisi penuh mulai tahun 2019, sedangkan tahun 2011–2018 hanya memiliki Happiness Score tanpa breakdown driver. Oleh karena itu, analisis hubungan antar-variabel

pada tahap selanjutnya difokuskan ke subset 2019–2024 (847 baris, 151 negara), sementara analisis tren jangka panjang tetap menggunakan seluruh rentang 2011–2024.


4.3 Komposisi Negara Berdasarkan Benua



Gambar 2. Jumlah negara berdasarkan benua hasil konversi `country_converter`.

Dari 195 negara yang berhasil di-scraping, Afrika memiliki jumlah negara terbanyak (54 negara), diikuti oleh Asia (48 negara), Eropa (44 negara), Amerika (35 negara), dan Oseania (14 negara). Komposisi ini penting sebagai konteks pada analisis perbandingan Happiness Score antar-benua, karena jumlah negara yang tidak seimbang antar-benua (misalnya Oseania yang hanya 14 negara dibandingkan Afrika yang 54 negara) perlu diperhatikan saat menginterpretasikan rata-rata per benua, mengingat rata-rata dari kelompok berukuran kecil cenderung lebih rentan dipengaruhi oleh nilai ekstrem satu-dua negara saja.


4.4 Distribusi Happiness Score dan Variabel Driver



Gambar 3. Distribusi Happiness Score dan enam variabel driver pada data 2019–2024 ($n=847$).

Berdasarkan histogram di atas, Happiness Score menunjukkan bentuk distribusi yang relatif mendekati normal dengan puncak di sekitar nilai 6, meskipun terdapat sedikit ekor ke arah nilai rendah (sekitar 1,4–3) yang mengindikasikan adanya sejumlah kecil negara dengan tingkat kebahagiaan sangat rendah. Variabel GDP_per_Capita dan Social_Support juga menunjukkan pola distribusi yang cukup mendekati normal, meskipun dengan beberapa puncak lokal (multimodal ringan). Sebaliknya, variabel Generosity dan Perceptions_of_Corruption menunjukkan pola right-skewed yang jelas, artinya mayoritas negara memiliki nilai rendah pada kedua variabel tersebut, dengan hanya sebagian kecil negara yang memiliki nilai tinggi.


Ringkasan statistik deskriptif pada rentang data 2019–2024 ($n=847$) menunjukkan Happiness Score memiliki rata-rata 5,52 dengan standar deviasi 1,13, rentang dari minimum 1,364 hingga maksimum 7,842. Variabel GDP_per_Capita memiliki rata-rata 1,21 (rentang 0 – 2,209), sedangkan Generosity memiliki rata-rata jauh lebih rendah yaitu 0,154 (rentang 0 – 0,570), mencerminkan skala dan pola distribusi yang berbeda antar variabel driver.



Gambar 4. Boxplot sebaran dan potensi outlier variabel driver (2019–2024).

Boxplot pada Gambar 4 memperkuat temuan dari histogram: variabel Generosity dan Perceptions_of_Corruption memiliki banyak titik outlier di sisi atas (nilai tinggi), konsisten dengan pola right-skewed yang teramati sebelumnya. Variabel GDP_per_Capita, Social_Support, Healthy_Life_Expectancy, dan Freedom relatif lebih simetris dengan sedikit outlier.

4.5 Negara dengan Happiness Score Tertinggi dan Terendah



Gambar 5. Sepuluh negara paling bahagia versus sepuluh negara paling tidak bahagia pada tahun 2024.

Pada tahun 2024, Finlandia menempati posisi Happiness Score tertinggi (7,736), diikuti oleh Denmark (7,521), Islandia (7,515), Swedia (7,345), dan Belanda (7,306) — seluruhnya negara Eropa, kecuali Kosta Rika yang berada di posisi keenam (7,274) dan Meksiko di posisi kesepuluh (6,979) yang mewakili benua Amerika. Israel juga masuk sepuluh besar (posisi kedelapan, 7,234) mewakili benua Asia. Pada sisi berlawanan, Afghanistan memiliki Happiness Score terendah secara signifikan (sekitar 1,364), jauh terpaut dari negara-negara terbawah lainnya seperti Sierra Leone, Lebanon, dan Malawi yang berada pada kisaran 3,0–3,3. Kesenjangan yang sangat lebar antara kelompok teratas dan terbawah — dari sekitar 7,8 hingga 1,4 — mengonfirmasi bahwa variasi kebahagiaan antarnegara di dunia sangat besar.


4.6 Korelasi Antar-Variabel terhadap Happiness Score



Gambar 6. Matriks korelasi antara Happiness Score, keenam variabel driver, dan tiga variabel geografis/populasi pada tahun 2024.

Matriks korelasi pada tahun 2024 menunjukkan bahwa Social_Support memiliki korelasi tertinggi terhadap Happiness Score (0,82), diikuti oleh GDP_per_Capita (0,77), Healthy_Life_Expectancy (0,72), dan Freedom (0,63). Perceptions_of_Corruption memiliki korelasi sedang (0,43), sementara Generosity nyaris tidak berkorelasi (0,05). Yang menarik, variabel-variabel geografis dan demografis — Population, Land Area (Km²), dan Density (P/Km²) — memiliki korelasi yang sangat lemah bahkan mendekati nol terhadap Happiness Score (berturut-turut -0,06, 0,10, dan 0,07), yang mengindikasikan bahwa ukuran atau kepadatan penduduk suatu negara bukan merupakan faktor yang berhubungan kuat dengan tingkat kebahagiaan penduduknya — berbeda dengan faktor sosial-ekonomi seperti dukungan sosial dan pendapatan per kapita.

Hasil serupa juga diperoleh pada perhitungan korelasi menggunakan data gabungan tahun 2019–2024 (bukan hanya 2024 saja), dengan urutan kekuatan korelasi yang konsisten: Social_Support (0,8175), GDP_per_Capita (0,7696), Healthy_Life_Expectancy (0,7202), Freedom (0,6321), Perceptions_of_Corruption (0,4289), sedangkan Land Area, Density, Generosity, dan Population seluruhnya berada di bawah 0,10. Konsistensi urutan ini pada dua cara perhitungan berbeda (snapshot 2024 saja versus gabungan 2019–2024) memperkuat keyakinan bahwa pola hubungan tersebut bukan kebetulan pada satu tahun tertentu, melainkan pola yang relatif stabil.




Gambar 7. Scatter plot dengan garis regresi untuk tiga driver dengan korelasi terkuat terhadap Happiness Score: Social_Support, GDP_per_Capita, dan Healthy_Life_Expectancy.

Scatter plot pada Gambar 7 menunjukkan bahwa hubungan antara ketiga driver dengan korelasi tertinggi tersebut dan Happiness Score memang tampak cukup linear, sejalan dengan nilai korelasi Pearson yang tinggi. Sebaran titik data pada ketiga grafik cukup rapat di sekitar garis regresi, meskipun tetap terdapat variasi (noise) yang wajar, khususnya pada nilai Social_Support dan GDP_per_Capita rendah di mana beberapa negara memiliki Happiness Score yang tersebar cukup lebar (misalnya pada GDP_per_Capita mendekati 0, Happiness Score bervariasi dari sekitar 1,4 hingga 5,6).

Sebagai catatan tambahan, scatter plot pada notebook scraping (yang mengeksplorasi hubungan antara Population dan Happiness Score dengan skala logaritmik pada sumbu populasi) juga memperlihatkan bahwa titik-titik data tersebar tanpa pola arah yang jelas terhadap Happiness Score, memvisualisasikan secara langsung mengapa korelasi antara Population dan Happiness Score sangat lemah (mendekati nol) seperti telah ditemukan pada matriks korelasi.


4.7 Tren Happiness Score dari Waktu ke Waktu



Gambar 8. Tren rata-rata Happiness Score dunia tahun 2011–2024, dengan pita berupa rata-rata ± 1 standar deviasi.


Rata-rata Happiness Score dunia relatif stabil sepanjang periode 2011–2024, bergerak pada kisaran sempit sekitar 5,34 hingga 5,57. Tidak tampak tren penurunan maupun kenaikan yang tajam; sedikit kenaikan bertahap justru terlihat setelah tahun 2019, mencapai titik tertinggi pada 2024 (sekitar 5,57). Pita ± 1 standar deviasi yang cukup lebar (kira-kira antara 4,2 hingga 6,7) menunjukkan bahwa variasi Happiness Score antarnegara pada satu tahun tertentu jauh lebih besar dibandingkan variasi rata-rata dunia dari tahun ke tahun — dengan kata lain, perbedaan antarnegara jauh lebih dominan dibandingkan perubahan dari waktu ke waktu.

4.8 Perbandingan Happiness Score Antar-Benua



Gambar 9. Rata-rata Happiness Score per benua pada tahun 2024.

Oseania mencatatkan rata-rata Happiness Score tertinggi (7,22), diikuti Eropa (6,27), Amerika (6,12), Asia (5,28), dan Afrika sebagai yang terendah (4,38). Perlu dicatat bahwa rata-rata Oseania yang sangat tinggi ini perlu dibaca dengan hati-hati mengingat jumlah negara Oseania yang memiliki data Happiness relatif sedikit dibandingkan benua lain (dari 14 negara Oseania hasil scraping, hanya sebagian yang memiliki data WHR), sehingga rata-ratanya lebih rentan dipengaruhi oleh beberapa negara maju seperti Australia dan Selandia Baru yang dominan dalam data tersebut.



Gambar 10. Sebaran (boxplot) Happiness Score per benua pada tahun 2024.

Boxplot pada Gambar 10 memberikan gambaran yang lebih kaya dibandingkan sekadar rata-rata: meskipun Afrika memiliki rata-rata terendah, rentang sebarannya (interquartile range) relatif sempit dan berada konsisten di bawah benua lain. Sebaliknya, Asia menunjukkan sebaran yang sangat lebar dengan satu outlier ekstrem di bagian bawah (merujuk pada Afghanistan dengan skor sekitar 1,4), menandakan bahwa di dalam benua Asia sendiri terdapat kesenjangan kebahagiaan yang sangat besar antarnegara. Eropa dan Amerika memiliki median yang berdekatan namun sebaran Amerika sedikit lebih lebar. Temuan ini menegaskan bahwa benua bukan satu-satunya penentu tingkat kebahagiaan suatu negara, karena variasi di dalam satu benua bisa jadi lebih besar dibandingkan perbedaan rata-rata antar-benua.

4.9 Pemeriksaan Multikolinearitas (VIF)

Sebelum melakukan regresi OLS sebagai alat bantu eksplorasi, dilakukan pemeriksaan multikolinearitas menggunakan Variance Inflation Factor (VIF) terhadap keenam variabel driver. Hasilnya adalah sebagai berikut:


Variabel	Nilai VIF
const	1,00
GDP_per_Capita	2,13
Social_Support	2,15
Healthy_Life_Expectancy	1,58
Freedom	1,57
Generosity	1,15

Variabel	Nilai VIF
Perceptions_of_Corruption	1,36

Seluruh nilai VIF berada jauh di bawah ambang batas umum sebesar 5 (nilai tertinggi hanya 2,15 pada Social_Support), sehingga dapat disimpulkan tidak terdapat masalah multikolinearitas yang serius di antara keenam variabel driver. Hal ini memberi keyakinan bahwa interpretasi koefisien individual pada regresi OLS berikutnya tidak terdistorsi oleh hubungan antar-variabel penjelas yang terlalu erat, meskipun beberapa di antaranya (seperti Social_Support dan GDP_per_Capita) memang memiliki korelasi cukup tinggi satu sama lain (0,71-0,72 pada matriks korelasi sebelumnya).

4.10 Regresi OLS sebagai Alat Bantu Eksplorasi

Regresi OLS dijalankan pada data 2019–2024 ($n=847$) dengan Happiness Score sebagai variabel dependen dan keenam driver sebagai variabel independen, menggunakan standard error robust (HC3). Model menghasilkan R-squared sebesar 0,722, yang berarti sekitar 72,2% variasi Happiness Score dapat dijelaskan secara bersama-sama oleh keenam variabel driver tersebut — sebuah nilai yang cukup tinggi untuk data lintas-negara semacam ini.



Gambar 11. Koefisien regresi OLS keenam driver terhadap Happiness Score (2019-2024, data pooled).

Seluruh koefisien pada model OLS bernilai positif dan signifikan secara statistik ($p < 0,001$ untuk seluruh variabel). Berdasarkan besaran koefisiennya, Healthy_Life_Expectancy memiliki koefisien terbesar (1,594), diikuti Generosity (1,423), Perceptions_of_Corruption (1,136), Freedom (0,924), Social_Support (0,793), dan GDP_per_Capita (0,710). Menariknya, urutan besaran koefisien pada regresi OLS ini berbeda dari urutan kekuatan korelasi sederhana yang dibahas pada bagian 4.6 — pada korelasi sederhana Social_Support dan GDP_per_Capita berada di posisi teratas, sedangkan pada

koefisien OLS justru `Healthy_Life_Expectancy` dan `Generosity` yang memiliki koefisien terbesar. Perbedaan ini terjadi karena koefisien OLS mengukur pengaruh suatu variabel ketika variabel lain dikontrol (*held constant*), sedangkan korelasi sederhana hanya mengukur hubungan dua variabel secara terpisah tanpa mengontrol variabel lain; skala variabel yang berbeda-beda (misalnya `Generosity` berkisar 0–0,57 sedangkan `GDP_per_Capita` berkisar 0–2,2) juga memengaruhi besaran koefisien mentah tersebut, sehingga koefisien tidak dapat langsung dibandingkan sebagai ukuran "kepentingan relatif" tanpa standardisasi lebih lanjut.

Sebagai catatan metodologis, model OLS ini digunakan murni sebagai alat bantu eksplorasi untuk melihat arah dan kekuatan hubungan gabungan antar-variabel, bukan sebagai model prediktif final — tidak dilakukan pembagian data latih/uji (*train/test split*), tuning hyperparameter, maupun validasi silang, sehingga *R-squared* sebesar 0,722 tidak dapat langsung diinterpretasikan sebagai ukuran akurasi prediksi di luar sampel.

5. Kesimpulan

Praktikum ini berhasil mempraktikkan alur kerja data science end-to-end mulai dari pengumpulan data melalui web scraping hingga analisis eksplorasi data. Pada tahap pertama, tiga sumber data berbeda — *Worldometers* (195 negara beserta luas wilayah), *Our World in Data* (populasi historis dan proyeksi 1950–2100), dan *World Happiness Report 2025* (*Happiness Score* dan enam variabel penjelas, 2011–2024) — berhasil diambil melalui teknik scraping HTML dan unduhan berkas langsung, kemudian dibersihkan dan digabungkan menjadi satu dataset panel negara-tahun berukuran 17.550 baris yang diekspor sebagai `dataset_country_population_happiness.csv`. Proses ini menuntut penanganan yang cermat terhadap perbedaan penamaan negara antar sumber, yang diselesaikan melalui pemetaan manual hingga seluruh nama negara berhasil dicocokkan.

Pada tahap EDA, dataset hasil scraping tersebut dianalisis untuk menjawab tujuan praktikum, yaitu mengidentifikasi faktor-faktor yang berhubungan dengan *Happiness Score*. Hasil analisis menunjukkan bahwa `Social_Support`, `GDP_per_Capita`, dan `Healthy_Life_Expectancy` secara konsisten memiliki korelasi terkuat terhadap *Happiness Score* (di atas 0,7), baik pada perhitungan korelasi tahun 2024 saja maupun pada data gabungan 2019–2024, sementara variabel geografis dan demografis seperti populasi, luas wilayah, dan kepadatan penduduk hampir tidak berkorelasi dengan tingkat kebahagiaan. Pemeriksaan VIF memastikan tidak ada masalah multikolinearitas serius di antara keenam driver (VIF maksimum 2,15), dan regresi OLS sebagai alat bantu eksplorasi mengonfirmasi bahwa keenam driver secara bersama-sama mampu menjelaskan 72,2% variasi *Happiness Score*,

dengan `Healthy_Life_Expectancy` dan `Generosity` menunjukkan koefisien terbesar ketika variabel lain dikontrol.

Dari sisi pola waktu dan wilayah, rata-rata Happiness Score dunia relatif stabil sepanjang 2011–2024 dengan sedikit kenaikan bertahap setelah 2019, sedangkan perbandingan antar-benua menunjukkan Oseania dan Eropa secara konsisten berada di posisi teratas, sementara Afrika berada di posisi terendah — meskipun boxplot per benua menegaskan bahwa variasi di dalam satu benua (terutama Asia) tetap besar sehingga benua bukan satu-satunya penentu. Secara keseluruhan, seluruh tujuan praktikum tercapai: teknik web scraping berhasil diterapkan untuk mengumpulkan data dari sumber heterogen, proses integrasi data berhasil menyatukan ketiganya menjadi dataset analitis yang konsisten, dan EDA berhasil mengungkap pola serta hubungan bermakna antara faktor sosial-ekonomi dengan tingkat kebahagiaan negara-negara di dunia, dengan catatan bahwa temuan ini bersifat eksploratif-korelasional dan memerlukan tahap pemodelan kausal terpisah apabila ingin ditarik klaim sebab-akibat.