

Laporan Exploratory Data Analysis Dan Preprocessing Dataset House Prices

Aziz Rahmad Arifin 5054251002

1. Pendahuluan

Analisis ini dilakukan terhadap dataset House Prices yang terdiri dari 1.460 observasi rumah dengan 81 atribut. Tujuan analisis adalah memahami struktur dan karakteristik data, melakukan pembersihan dan persiapan data untuk tahap pemodelan prediktif harga rumah (SalePrice). Proses mencakup eksplorasi data, penanganan nilai hilang, deteksi outlier, transformasi fitur kategorikal, standardisasi, analisis korelasi, dan reduksi dimensi menggunakan Principal Component Analysis (PCA).


2. Exploratory Data Analysis (EDA)

2.1 Struktur dan Dimensi Dataset

Dataset train berukuran 1.460 baris dengan 81 kolom. Komposisi tipe data adalah 43 kolom bertipe object (kategorikal), 35 kolom bertipe int64 (numerik), dan 3 kolom bertipe float64 (numerik). Setiap baris merepresentasikan satu observasi rumah dengan Id unik yang berkisar dari 1 hingga 1.460.

2.2 Statistik Deskriptif dan Distribusi Target (SalePrice)

Variabel target SalePrice memiliki distribusi yang miring ke kanan (right-skewed) dengan skewness sebesar 1,8829. Statistik deskriptif menunjukkan harga minimum \$34.900, harga maksimum \$755.000, rata-rata \$180.921, median \$163.000, dan standar deviasi \$79.442. Distribusi ini menunjukkan bahwa sebagian besar rumah memiliki harga di bawah rata-rata dengan beberapa rumah berkualitas tinggi yang menarik harga signifikan lebih tinggi.




Gambar 2.1: Distribusi dan Boxplot SalePrice

2.3 Nilai Hilang (Missing Values)

Pemeriksaan mengidentifikasi 19 kolom dengan nilai hilang. Berdasarkan kriteria yang disepakati, kolom dengan persentase missing value lebih dari 50% dihapus: PoolQC (99,52%), MiscFeature (96,30%), Alley (93,77%), Fence (80,75%), dan MasVnrType (59,73%). Penghapusan lima kolom ini meninggalkan 76 kolom untuk diproses lebih lanjut.

2.4 Fitur Top Berpengaruh terhadap SalePrice

Analisis korelasi mengidentifikasi 10 fitur numerik dengan korelasi tertinggi terhadap SalePrice: (1) OverallQual (0,7910), (2) GrLivArea (0,7086), (3) GarageCars (0,6404), (4) GarageArea (0,6234), (5) TotalBsmtSF (0,6136), (6) 1stFlrSF (0,6059), (7) FullBath (0,5607), (8) TotRmsAbvGrd (0,5337), (9) YearBuilt (0,5229), (10) YearRemodAdd (0,5071). Fitur-fitur ini menunjukkan pengaruh positif yang konsisten terhadap harga rumah.




Gambar 2.2: Top 10 Fitur Berkorelasi dan Hubungan OverallQual dengan SalePrice

2.5 Analisis Skewness Fitur Numerik

Dari 36 fitur numerik yang dianalisis, distribusinya terkategori: 19 fitur sangat miring ($|\text{Skewness}| > 1,0$), 10 fitur agak miring ($0,5 \leq |\text{Skewness}| \leq 1,0$), dan 7 fitur simetris ($|\text{Skewness}| < 0,5$). Fitur dengan skewness paling ekstrem adalah MiscVal (24,48), PoolArea (14,83), dan LotArea (12,21). Sebaliknya, OverallQual (0,22), MoSold (0,21), dan BedroomAbvGr (0,21) memiliki distribusi hampir simetris.


4 Fitur Numerik dengan Skewness Tertinggi



Gambar 2.3: 4 Fitur Numerik dengan Skewness Tertinggi

2.6 Analisis Neighborhood (Lokasi)

Analisis pada 25 lokasi (neighborhood) menunjukkan variasi harga yang signifikan. Lokasi termahal adalah Northridge Heights (median \$315.000, rata-rata \$316.271), sedangkan lokasi termurah adalah Meadow Village (median \$88.000, rata-rata \$98.576). Perbedaan ini menunjukkan bahwa lokasi memiliki pengaruh penting terhadap harga rumah.



Gambar 2.4: Distribusi SalePrice Berdasarkan Neighborhood

3. Data Cleaning dan Preprocessing

3.1 Konversi Tipe Data

Fitur MSSubClass, meskipun berisi nilai numerik, merepresentasikan kode kategorikal untuk tipe bangunan (misalnya, 20 = 1-Story 1946 & Newer, 60 = 2-Story 1946 & Newer). Fitur ini dikonversi dari tipe data integer menjadi string untuk mencegah model menginterpretasikan perbedaan numerik sebagai hubungan ordinal kontinu.


3.2 Penanganan Nilai Hilang

Penanganan missing value dilakukan dengan strategi berbasis makna fitur: (1) Fitur kategorikal yang menunjukkan ketiadaan fasilitas diisi dengan "None"; (2) Fitur numerik yang menunjukkan ketiadaan fasilitas diisi dengan nilai 0; (3) LotFrontage diimputasi menggunakan median berdasarkan neighborhood; (4) Electrical diisi dengan modus; (5) GarageYrBlt diisi dengan 0 setelah verifikasi bahwa 81 observasi dengan nilai hilang tidak memiliki garasi. Setelah proses imputasi, tidak terdapat nilai hilang yang tersisa dalam dataset.

4. Deteksi dan Penanganan Outlier

4.1 Pemeriksaan GrLivArea


Fitur GrLivArea dipilih untuk analisis outlier karena merepresentasikan luas area hunian utama rumah dan berkorelasi kuat dengan harga. Pemeriksaan awal pada observasi dengan GrLivArea > 4.000 sqft mengidentifikasi empat rumah. Setelah ditinjau berdasarkan kombinasi luas bangunan, kualitas rumah, dan SalePrice, dua observasi (Id 524 dan 1299) dianggap sebagai anomali ekstrem karena menunjukkan pola tidak wajar: memiliki luas bangunan sangat besar tetapi harga jual jauh lebih rendah dibandingkan observasi dengan karakteristik serupa. Kedua observasi ini dihapus dari dataset.



Gambar 4.1: Deteksi Outlier GrLivArea dengan Threshold 4000 sqft

4.2 Metode Interquartile Range (IQR)

Setelah penghapusan dua outlier ekstrem, pemeriksaan menggunakan metode IQR dilakukan pada 1.458 observasi sisanya. Hasil perhitungan: $Q1 = 1.128,5$ sqft, $Q3 = 1.776,0$ sqft, $IQR = 647,5$ sqft, Upper Bound = $2.747,25$ sqft. Metode IQR menemukan 29 observasi yang berada di atas batas atas. Namun, observasi-observasi ini tidak dihapus karena status sebagai outlier statistik tidak berarti kesalahan data. Banyak dari observasi ini memiliki karakteristik yang valid (OverallQual tinggi, lokasi premium) yang menjelaskan harga tinggi mereka. Retensi observasi ini mempertahankan variasi data yang penting untuk model prediktif. Dataset akhir setelah penanganan outlier terdiri dari 1.458 observasi.



Gambar 4.2: Deteksi Outlier dengan Metode IQR

5. Analisis Skewness dan Pemilihan Fitur

Sebagaimana diuraikan dalam bagian EDA, analisis skewness menunjukkan 19 fitur dengan skewness sangat tinggi ($|\text{Skewness}| > 1,0$). Fitur-fitur yang paling miring (MiscVal, PoolArea, LotArea) menunjukkan distribusi yang sangat pincang ke kanan dengan banyak nilai nol atau rendah dan beberapa nilai ekstrem tinggi. Pemeriksaan skewness bertujuan untuk memahami karakteristik distribusi fitur sebelum normalisasi dan standardisasi. Fitur-fitur dengan skewness tinggi tetap dipertahankan dalam model karena proses standardisasi dan PCA yang akan dilakukan kemudian dapat menangani distribusi ini.

6. One-Hot Encoding dan Standardisasi

6.1 Pemisahan dan Encoding Fitur

Setelah cleaning dan preprocessing, dataset terdiri dari 75 fitur (dikurangi 1 karena kolom Id tidak digunakan sebagai prediktor). Pemisahan mengidentifikasi 39 fitur kategorikal dan 36 fitur numerik. One-Hot Encoding diterapkan pada 39 fitur kategorikal menggunakan ColumnTransformer dengan OneHotEncoder, mengkonversi setiap kategori menjadi variabel biner (0 atau 1). Hasil encoding

meningkatkan jumlah fitur dari 75 menjadi 295 fitur, sebuah peningkatan yang signifikan tetapi diperlukan untuk mempersiapkan data sebagai input model machine learning.


6.2 Standardisasi dengan StandardScaler

Standardisasi dilakukan menggunakan StandardScaler pada semua 295 fitur hasil encoding. Proses ini mengubah setiap fitur sehingga memiliki rata-rata mendekati 0 dan standar deviasi mendekati 1. Hasil verifikasi menunjukkan mean rata-rata semua fitur 0,000000 dan standar deviasi rata-rata 1,000343. Standardisasi penting sebelum PCA karena PCA sensitif terhadap perbedaan skala: fitur dengan nilai numerik besar akan mendominasi komponen utama jika tidak distandardisasi. Setelah standardisasi, semua fitur berkontribusi secara setara terhadap variance dalam analisis PCA.

7. Korelasi dan Multikolinearitas

7.1 Correlation Matrix

Analisis correlation matrix pada 35 fitur numerik mengidentifikasi lima pasangan fitur dengan korelasi tinggi ($|r| \geq 0,7$): (1) GarageCars–GarageArea (0,8873), (2) GrLivArea–TotRmsAbvGrd (0,8295), (3) TotalBsmtSF–1stFlrSF (0,8038), (4) OverallQual–SalePrice (0,7958), (5) GrLivArea–SalePrice (0,7350). Korelasi tinggi antara GarageCars dan GarageArea dapat dijelaskan secara struktural karena keduanya merepresentasikan dimensi berbeda dari garasi yang sama. Demikian pula, TotalBsmtSF secara matematis merupakan penjumlahan dari BsmtFinSF1, BsmtFinSF2, dan BsmtUnfSF. Korelasi dengan target SalePrice yang tinggi pada OverallQual dan GrLivArea mengonfirmasi pengaruh signifikan fitur-fitur ini terhadap harga.



Gambar 7.1: Correlation Matrix Fitur Numerik

7.2 Variance Inflation Factor (VIF)

Pemeriksaan VIF pada fitur numerik mengungkapkan multikolinearitas ekstrem pada delapan fitur (BsmtFinSF1, BsmtFinSF2, BsmtUnfSF, TotalBsmtSF, GrLivArea, LowQualFinSF, 2ndFlrSF, 1stFlrSF) dengan nilai VIF sekitar $1,0008 \times 10^{15}$. Nilai VIF yang sangat tinggi ini menunjukkan hubungan linear sempurna atau mendekati sempurna, yang dapat dijelaskan oleh struktur matematis dataset (misalnya, $\text{TotalBsmtSF} = \text{BsmtFinSF1} + \text{BsmtFinSF2} + \text{BsmtUnfSF}$). Fitur-fitur lain menunjukkan VIF yang lebih sedang: GarageCars (6,22), GarageArea (5,30), TotRmsAbvGrd (4,79), dan OverallQual (3,23). Meskipun multikolinearitas tinggi terdeteksi, fitur-fitur tersebut tidak langsung dihapus karena PCA yang diterapkan pada tahap berikutnya mampu menangani redundansi informasi ini dengan mengidentifikasi komponen-komponen ortogonal yang menangkap variance data.


8. Principal Component Analysis (PCA)

8.1 Tujuan dan Metodologi

PCA diterapkan untuk mengurangi dimensi data dari 295 fitur menjadi sejumlah kecil komponen utama yang mempertahankan sebagian besar variance informasi. Teknik ini membantu mengatasi multikolinearitas, mengurangi noise, dan mempercepat komputasi model machine learning dengan menghilangkan redundansi informasi.

8.2 Hasil Reduksi Dimensi


Aplikasi PCA pada data terstandarisasi menghasilkan kurva cumulative explained variance yang menunjukkan: (1) 148 principal components diperlukan untuk mempertahankan minimal 90% variance; (2) Variance yang dipertahankan oleh 148 komponen: 90,16%; (3) Pengurangan dimensi: 295 → 148 fitur (50% pengurangan). Hasil ini berarti informasi dalam 295 fitur dapat direpresentasikan dengan komponen-komponen yang jauh lebih ringkas tanpa kehilangan informasi penting.



Gambar 8.1: PCA Cumulative Explained Variance Ratio

8.3 Visualisasi PCA 2 Dimensi

Sebagai alat eksplorasi tambahan, PCA 2 dimensi diterapkan secara terpisah untuk visualisasi persebaran data. PC1 menjelaskan variance 6,38%, PC2 menjelaskan variance 3,02%, dengan total variance PC1 + PC2 sebesar 9,40%. Visualisasi scatter plot menunjukkan pola persebaran SalePrice dalam ruang 2 dimensi yang merepresentasikan komponen-komponen utama pertama dan kedua. Meskipun hanya menangkap 9,4% dari total variance, visualisasi ini memberikan wawasan tentang struktur data multidimensional dan hubungan nonlinear dalam dataset.



Gambar 8.2: Visualisasi PCA 2 Dimensi dengan SalePrice

8.4 Output PCA untuk Pemodelan

Hasil PCA 148 komponen disimpan dalam DataFrame dengan kolom-kolom bernama PC1, PC2, ..., PC148 dan dikombinasikan dengan variabel target SalePrice. Dataset final memiliki dimensi 1.458 baris $\times$ 149 kolom (148 principal components + 1 kolom SalePrice). Output ini disimpan dalam format CSV (train_final.csv) dan siap digunakan sebagai input untuk tahap pemodelan machine learning.

9. Kesimpulan

Proses EDA dan preprocessing secara sistematis mengubah dataset raw menjadi input yang siap untuk pemodelan machine learning:

EDA: mengidentifikasi karakteristik fundamental dataset: 1.460 observasi dengan 81 atribut, distribusi target yang miring, nilai hilang tersebar di 19 kolom, dan variasi signifikan di 36 fitur numerik.

Data Cleaning: menghapus lima kolom dengan missing value $> 50\%$, mengkonversi MSSubClass ke tipe kategorikal, dan mengimputasi missing value berdasarkan konteks fitur.

Deteksi Outlier: menerapkan dua pendekatan komplementer: pemeriksaan GrLivArea > 4.000 sqft mengidentifikasi dan menghapus dua anomali ekstrem (Id 524 dan 1299), sementara metode IQR menemukan 29 outlier statistik yang dipertahankan.

Encoding dan Standardisasi: mengkonversi 39 fitur kategorikal menjadi 295 fitur numerik melalui One-Hot Encoding, kemudian menstandarkan semua fitur ke skala yang sebanding.

Analisis Korelasi: mengungkapkan lima pasangan fitur dengan korelasi tinggi dan multikolinearitas ekstrem pada delapan fitur yang dapat dijelaskan oleh struktur matematis dataset.

Reduksi Dimensi: menggunakan PCA untuk mengompres 295 fitur menjadi 148 principal components yang mempertahankan 90,16% variance informasi.

Dataset akhir dengan 1.458 observasi dan 148 principal components plus target SalePrice mewakili data yang telah sepenuhnya disiapkan dan terstandarisasi, siap untuk eksperimen pemodelan machine learning seperti regresi linear, random forest, gradient boosting, atau model ensemble lainnya.