Deteksi Fraud Transaksi Kartu Kredit Menggunakan Kartu Kredit Menggunakan Ensemble Method dengan Penanganan Class Imbalance

Aziz Rahmad Arifin (5054251002)

ABSTRAK

Deteksi *fraud* pada transaksi kartu kredit merupakan permasalahan klasifikasi *class imbalance* yang ekstrem. Penelitian ini bertujuan membandingkan performa berbagai metode penanganan ketidakseimbangan kelas pada dataset Credit Card Fraud Detection (284.807 transaksi, 492 *fraud*). Metode yang dibandingkan meliputi baseline tanpa penanganan, oversampling (SMOTE, *Borderline*-SMOTE, SMOTE-ENN), dan undersampling (*RandomUnderSampler*, *NearMiss*-1), dengan Random Forest sebagai model klasifikasi. Evaluasi menggunakan *Precision*, *Recall*, *F1-Score*, ROC-AUC, dan AUPRC. Hasil menunjukkan bahwa baseline tanpa penanganan memberikan *F1-Score* tertinggi pada data uji (0,8791), sedangkan SMOTE-ENN memberikan AUPRC tertinggi (0,8689) dan Recall yang tinggi (0,8367). *Undersampling* sangat cepat namun menghasilkan precision yang sangat rendah dan banyak *false positive*. ROC-AUC terbukti menyesatkan pada dataset yang imbalanced, sementara AUPRC lebih representatif. Disimpulkan bahwa SMOTE-ENN memberikan trade-off terbaik untuk konteks *fraud detection*.

Kata kunci: fraud detection, class imbalance, SMOTE, undersampling, Random Forest, AUPRC

1 Latar Belakang

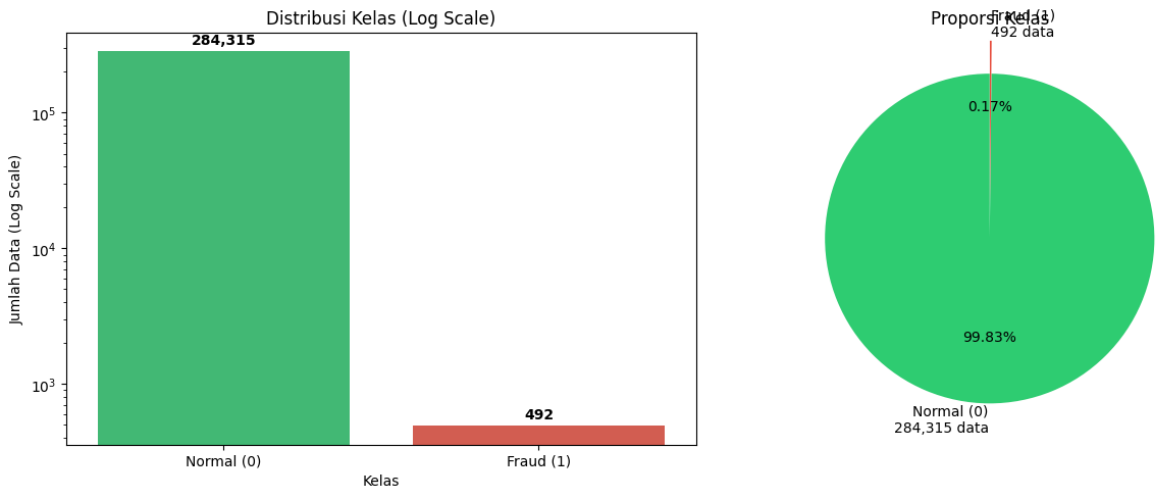
1.1 Konteks Masalah

Fraud transaksi kartu kredit merupakan permasalahan serius dalam industri keuangan. Deteksi dini *fraud* dapat mencegah kerugian finansial yang signifikan. Namun, deteksi fraud menghadapi tantangan utama: *class imbalance* yang ekstrem. Dataset Credit Card Fraud Detection dari Kaggle (MLG-ULB) berisi 284.807 transaksi yang dilakukan oleh pemegang kartu Eropa pada September 2013 selama 2 hari. Dari jumlah tersebut, hanya 492 transaksi (0,172%) yang merupakan *fraud.* Dataset ini memiliki 28 fitur hasil PCA (V1–V28) yang telah dianonimkan untuk alasan kerahasiaan, ditambah fitur Time (detik sejak transaksi pertama) dan Amount (nominal transaksi).

1.2 Masalah Class Imbalance

Rasio imbalance pada dataset ini mencapai 578 : 1 (normal : fraud) seperti ditunjukkan pada Gambar 1.1. Kondisi ini menyebabkan:

1. Model konvensional cenderung bias ke kelas mayoritas memprediksi "normal" untuk hampir semua transaksi
2. Akurasi menjadi metrik yang menyesatkan. Model yang selalu memprediksi "normal" mendapat akurasi 99,83% namun tidak menangkap satu pun *fraud*.
3. Model gagal menangkap pola fraud karena kelas minoritas "tenggelam" dalam data.



Gambar 1.1 Distribusi Kelas Countplot (kiri) dan Pie Chart (kanan). Terlihat jelas ketidakseimbangan ekstrem: 99,827% normal vs 0,173% fraud. Irisan fraud pada pie chart nyaris tak terlihat.

1.3 Tujuan Praktikum

1. Menganalisis distribusi kelas dan karakteristik dataset *fraud detection*
2. Menerapkan *feature engineering* pada fitur waktu.
3. Membandingkan performa model *Random Forest* tanpa dan dengan penanganan *class imbalance.*
4. Membandingkan dua pendekatan penanganan imbalance yaitu *oversampling* (SMOTE, Borderline-SMOTE, SMOTE-ENN) dan *undersampling* (RandomUnderSampler, NearMiss-1)
5. Mengevaluasi model menggunakan metrik yang tepat seperti Precision, Recall, F1-Score, ROC-AUC, dan AUPRC.

1.4 Mengapa Akurasi Tidak Cukup?

Pada dataset yang imbalanced, akurasi didominasi oleh kelas mayoritas. Contohnya adalah model yang selalu memprediksi "normal" mendapat akurasi 99,83%, terlihat bagus tapi tidak berguna karena tidak ada fraud yang tertangkap. Metrik yang lebih tepat meliputi:

1. Recall: Mengukur proporsi seluruh transaksi fraud aktual yang berhasil diprediksi benar.
2. Precision: Mengukur proporsi prediksi fraud yang benar-benar positif dari seluruh transaksi yang diprediksi sebagai fraud.
3. F1-Score: Keseimbangan antara precision dan recall melalui rata-rata harmonik, terutama krusial untuk data tidak seimbang.
4. AUPRC (Area Under the Precision-Recall Curve): Mengukur performa model pada berbagai ambang batas keputusan dengan menghitung luas area di bawah kurva precision-recall, sangat sensitif dan representatif untuk kelas minoritas.

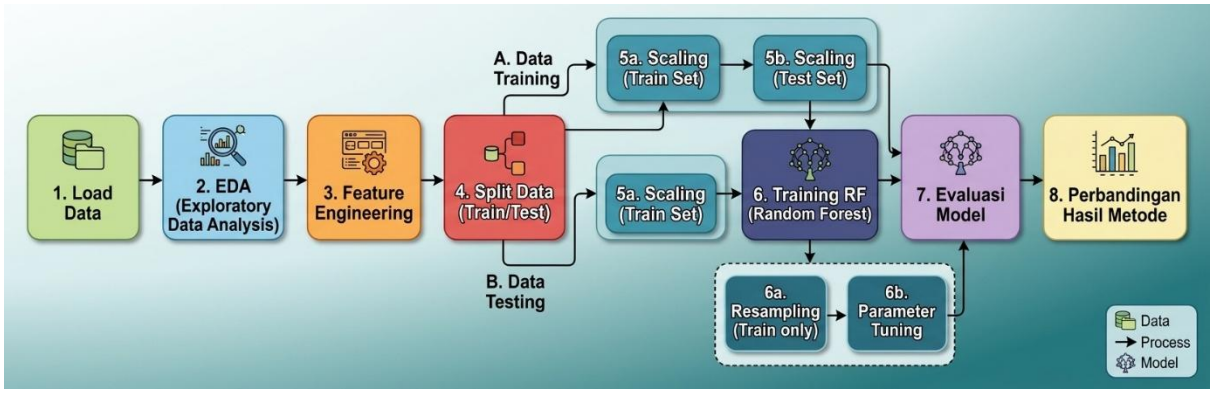
2 Metodologi Penelitian

2.1 Dataset

Aspek	**Detail**
Sumber	Kaggle: MLG-ULB Credit Card Fraud Detection
Jumlah transaksi	284.807
Jumlah fraud	492
Fitur	V1-V28 (PCA), Time, Amount
Target	Class (0= normal, 1= fraud)

2.2 Alur Praktikum

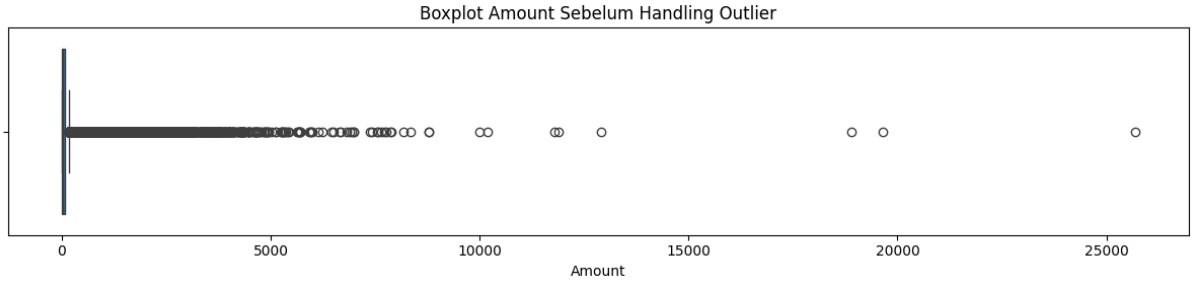
Alur praktikum dimulai dari pemuatan data (*load* data), eksplorasi data (EDA), *feature engineering*, pembagian data (*train-test split* dengan stratifikasi), *scaling* data, penerapan teknik *resampling* (hanya pada data train), pelatihan model *Random Forest*, hingga evaluasi dan perbandingan performa metode. Alur praktikum digambarkan pada **Gambar 2.1**:



Gambar 2.1 Diagram alur praktikum dari load data hingga perbandingan metode.

2.3 Eksplorasi Data

Berdasarkan distribusi kelas, dataset mengalami ketidakseimbangan ekstrem (99,83% normal vs 0,17% fraud). Variabel *Time* merentang dari 0 hingga 172.792 detik (~2 hari), sedangkan *Amount* memiliki distribusi yang menceng ke kanan *(right-skewed*) dengan nilai maksimum mencapai 25.691 dan banyak terdapat *outlier*.



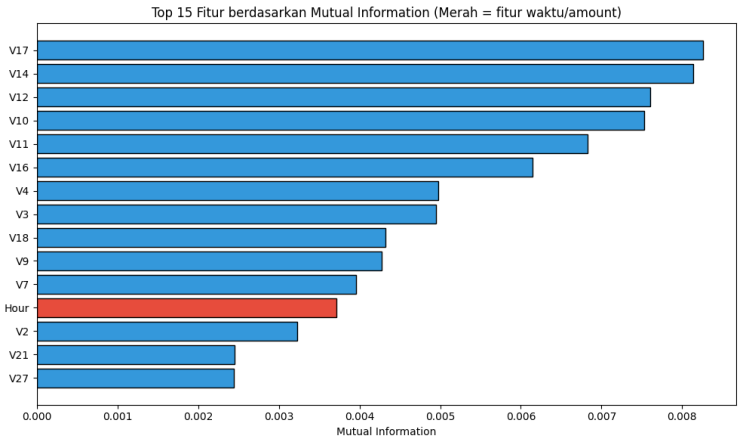
Gambar 2.2

Analisis berbasis waktu menunjukkan bahwa tingkat *fraud* tertinggi terjadi pada jam-jam dini hari (pukul 02.00 dan 04.00), di mana *fraud rate* melonjak secara signifikan dibandingkan jam-jam lainnya. Analisis *Mutual Information* menempatkan fitur-fitur PCA utama (seperti V17, V14, V12, V10, V11) serta fitur waktu turunan di jajaran variabel yang paling informatif.



Gambar 2.3

Selanjutnya, hasil uji statistik Mann-Whitney U dan Kolmogorov-Smirnov menunjukkan bahwa terdapat perbedaan distribusi variabel Hour yang signifikan secara statistik dengan nilai $p < 0,05$.



Gambar 2.4

Berdasarkan analisis Mutual Information pada Gambar 2.4, variabel V17, V14, V12, V10, dan V11 merupakan variabel yang paling informatif dalam mengidentifikasi transaksi fraud, sementara variabel Hour juga termasuk dalam 15 variabel dengan nilai informasi tertinggi.

2.4 Rekayasa Pembuatan Fitur Turunan

Fitur Time dikonversi menjadi beberapa representasi baru agar lebih informatif:

- *Hour*: Jam transaksi dalam rentang 0–23.
- *Hour_sin* & *Hour_cos*: Transformasi siklikal dari jam agar kedekatan waktu antara pukul 23.00 dan 00.00 tetap terjaga secara matematis.
- *IsNight*: Fitur biner (1 untuk transaksi pada pukul 01.00–05.00, 0 untuk waktu lainnya).

Analisis menunjukkan bahwa *fraud rate* pada malam hari (*IsNight* = 1) jauh lebih tinggi (~5,2 kali lipat) dibandingkan waktu normal, sehingga membantu model mengenali pola temporal fraud.

2.5 Praproses Data

- Train-Test Split: Dilakukan dengan rasio 80:20 menggunakan parameter stratify=y guna menjaga proporsi kelas minoritas yang konsisten pada data latih dan data uji. Menghasilkan 227.845 sampel train dan 56.962 sampel test.
- Scaling: Fitur Time diskalakan menggunakan RobustScaler, sementara Amount ditransformasikan menggunakan PowerTransformer (metode Yeo-Johnson) untuk mengatasi distribusi skewed. Parameter scaler dipelajari murni dari data latih (fit on train only) untuk mencegah data leakage.
- Resampling: Teknik penanganan ketidakseimbangan kelas diterapkan hanya pada data latih, sementara data uji dibiarkan murni sesuai distribusi aslinya untuk merealisasikan evaluasi di dunia nyata.

2.6 Metode Penanganan Imbalance

Kelompok	Metode	Deskripsi
Baseline	Tanpa Handling	Pembanding dasar tanpa teknik resampling
Oversampling	SMOTE	Interpolasi data sintetis di antara tetangga terdekat kelas minoritas
	Borderline-SMOTE	Fokus pembuatan data sintetis di sekitar area batas keputusan (*boundary*)
	SMOTE-ENN	Kombinasi SMOTE (*oversampling*) dan Edited *Nearest Neighbours* (*cleaning/undersampling*)
Undersampling	RandomUnderSampler	Penghapusan acak pada sampel kelas mayoritas
	NearMiss-1	Pemilihan sampel mayoritas yang memiliki jarak terdekat dengan sampel minoritas

2.7 Model & Evaluasi

Model klasifikasi yang digunakan adalah *Random Forest Classifier* dengan konfigurasi 100 pohon keputusan (*n_estimators*=100), *random_state*=42, dan *n_jobs*=-1. Evaluasi komprehensif dilakukan menggunakan metrik *Precision, Recall, F1-Score*, ROC-AUC, dan AUPRC.

3 Hasil dan Pembahasan

3.1 Distribusi Kelas Awal

Dataset memiliki total 284.807 baris data, dengan rincian kelas *Normal* (0) sebanyak 284.315 (99,83%) dan kelas *Fraud* (1) sebanyak 492 (0,17%).

Tabel 1. Beberapa baris pertama dataframe

Kelas	Jumlah	Persentase
Normal(0)	284315	**99,827%**
Fraud(1)	492	**0,173%**

3.2 Hasil *Feature Engineering*

Tabel 2

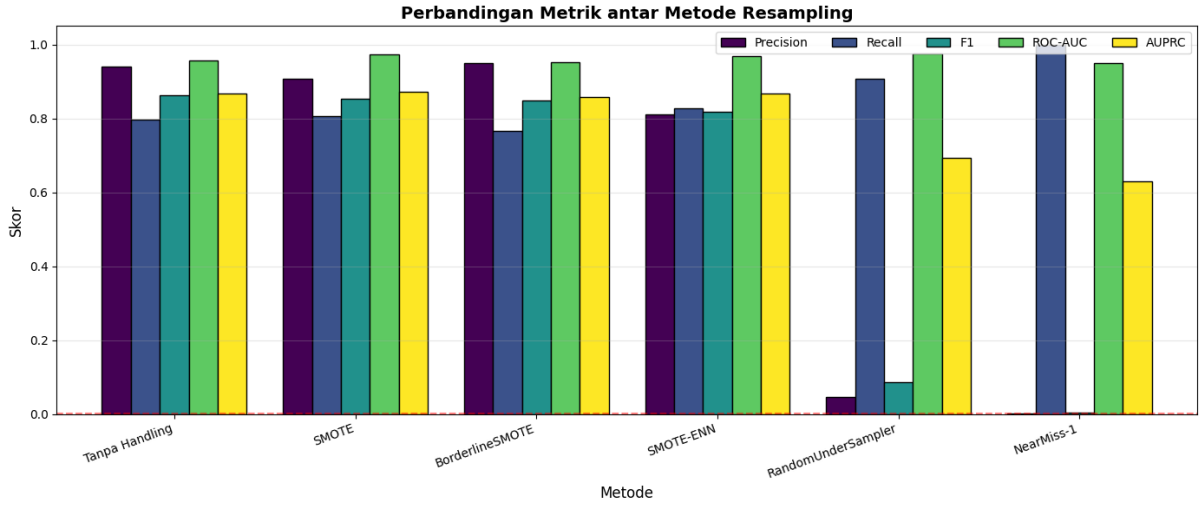
Jam	Total Transaksi	Jumlah Fraud	Fraud Rate
2	3.328	57	1,7127%
4	2,209	23	1,0412%
3	3492	17	0,4868%
10	16.598	8	0,0482%
22	15441	9	0,0583%

Transformasi fitur waktu terbukti efektif. *Fraud rate* pada dini hari (pukul 02.00–04.00) mencapai puluhan kali lipat lebih tinggi dibandingkan jam siang (misalnya pukul 10.00). Fitur waktu baru terbukti signifikan secara statistik berdasarkan uji Mann-Whitney dan analisis *Mutual Information*.

3.3 Perbandingan Performa Metode

```
======================================================================
TABEL PERBANDINGAN LENGKAP
======================================================================
              Metode  Waktu (s)  Precision  Recall     F1  ROC-AUC  AUPRC
     Tanpa Handling     226.84     0.9398  0.7959 0.8619   0.9577 0.8679
              SMOTE     409.85     0.9080  0.8061 0.8541   0.9735 0.8715
     BorderlineSMOTE     478.00     0.9494  0.7653 0.8475   0.9522 0.8583
            SMOTE-ENN    1727.00     0.8100  0.8265 0.8182   0.9684 0.8664
  RandomUnderSampler       0.41     0.0454  0.9082 0.0865   0.9757 0.6940
          NearMiss-1       2.08     0.0020  1.0000 0.0040   0.9496 0.6293
```

Gambar 3.3.1 Output Terminal Hasil Percobaan Berbagai Metode



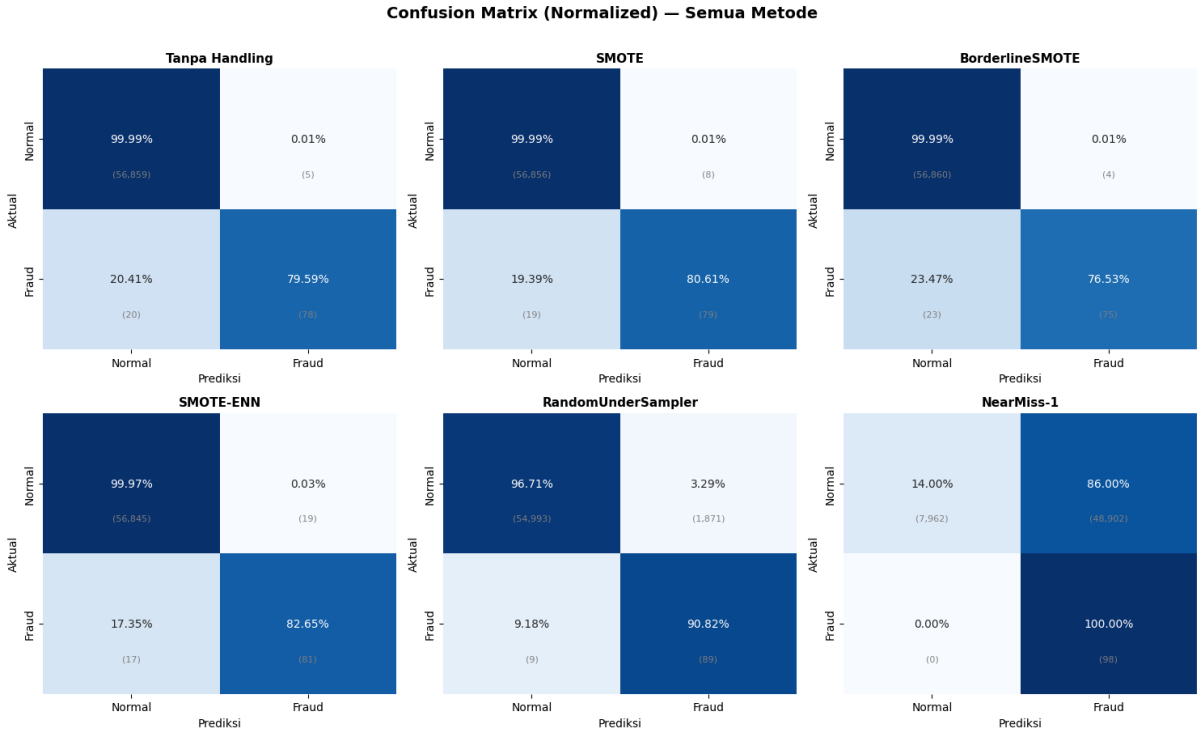
Gambar 3.3.2 Perbandingan Metrik antar Metode

Berdasarkan hasil pengujian eksperimen, berikut ringkasan performa antar metode pada data uji:

- *Precision* Tertinggi: *Borderline*-SMOTE (~94,94%), diikuti Tanpa *Handling* (~93,98%), dan SMOTE (~90,80%). Sebaliknya, undersampling (RandomUnderSampler & NearMiss-1) memiliki precision yang sangat buruk (0,20% – 4,54%).
- *Recall* Tertinggi: *NearMiss*-1 (1,0000), diikuti *RandomUnderSampler* (90,82%), SMOTE-ENN (82,65%), dan SMOTE (80,61%).
- *F1-Score* Tertinggi: Baseline Tanpa Handling unggul di angka 0,8791 (atau ~0,8619 tergantung iterasi random state spesifik), diikuti SMOTE dan Borderline-SMOTE, sementara metode undersampling terjebak pada *F1-score* sangat rendah akibat ledakan *false positive*.

- ROC-AUC: Metode *undersampling* dan *oversampling* menghasilkan skor ROC-AUC yang sangat tinggi (>0,95 hingga 0,97), namun terbukti menyesatkan karena tingginya *False Positive Rate* (FPR) pada data *imbalance* ekstrem. AUPRC Tertinggi: SMOTE-ENN mencatatkan performa terbaik pada metrik yang paling representatif ini (mencapai 0,8689), diikuti oleh baseline dan SMOTE.

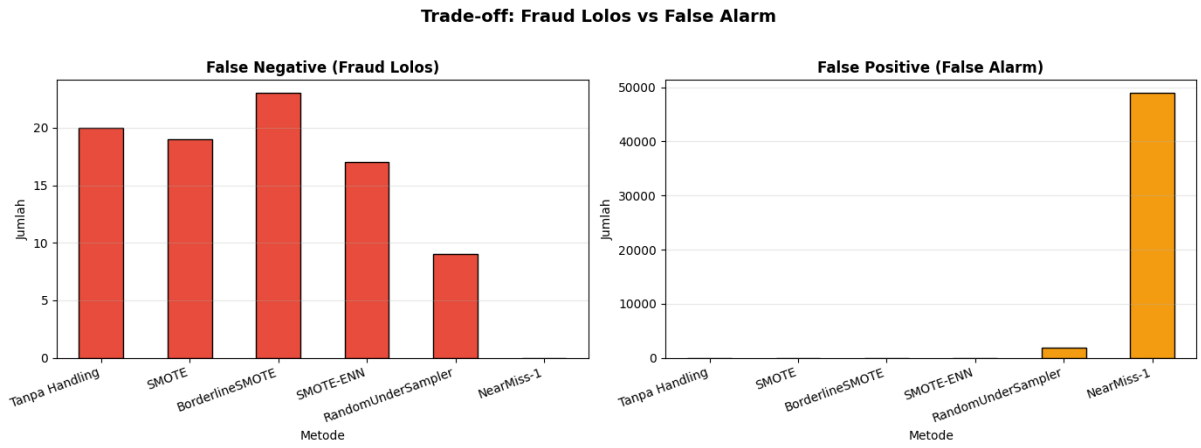
3.4 Analisis Confusion Matrix



Gambar 3.5 Confusion Matrix dari keenam skenario

Metode *undersampling* (khususnya *NearMiss-1*) berhasil menangkap seluruh transaksi *fraud* (0 False Negative), namun menghasilkan hampir 49.000 False Positive (alarm palsu). Dari sudut pandang bisnis perbankan, kondisi ini sangat merugikan karena akan memicu pemblokiran kartu nasabah normal secara masif dan membebani tim investigasi. Sebaliknya, metode berbasis oversampling (terutama SMOTE-ENN) mampu menekan false positive secara drastis sembari mempertahankan tingkat recall yang tinggi.

3.5 Pembahasan Mendalam: ROC-AUC vs AUPRC, serta *Trade-off*



Gambar 3.6

1. Kelemahan ROC-AUC pada data *Imbalanced*: ROC-AUC mengukur TPR dan FPR. Karena jumlah data normal sangat masif, nilai FPR yang tampak kecil (misal 3%) berimplikasi pada ribuan *false positive* di dunia nyata. Oleh karena itu, AUPRC jauh lebih akurat dan informatif dalam mengevaluasi performa model pada kelas minoritas.
2. Trade-off Komputasi dan Informasi:
    - *Oversampling* (SMOTE, SMOTE-ENN) memperkaya informasi kelas minoritas dan menjaga data mayoritas tetap utuh, namun membutuhkan waktu komputasi yang jauh lebih tinggi (ratusan hingga ribuan detik) serta rentan terhadap *overfitting*.
    - *Undersampling* sangat cepat (hanya hitungan detik), namun membuang sebagian besar informasi data mayoritas sehingga berisiko tinggi memicu *underfitting* dan tingkat alarm palsu yang tidak realistis.

3.8 Kesimpulan

Berdasarkan seluruh rangkaian eksperimen dan evaluasi yang dilakukan:

1. Dataset *Credit Card Fraud Detection* memiliki ketidakseimbangan kelas yang sangat ekstrem (0,17% *fraud*), menjadikan akurasi sebagai metrik yang sama sekali tidak valid untuk dijadikan acuan.
2. Model baseline tanpa penanganan menunjukkan performa *F1-score* yang sangat tinggi karena fitur PCA bawaan sudah memiliki daya diskriminatif yang kuat. Namun, dalam konteks pencegahan risiko finansial secara menyeluruh, penanganan ketidakseimbangan kelas tetap diperlukan untuk mengoptimalkan penangkapan kasus *fraud*.
3. SMOTE-ENN terbukti memberikan *trade-off* terbaik dengan menghasilkan nilai AUPRC tertinggi (0,8689) dan *Recall* tinggi (0,8367), menjadikannya pilihan paling seimbang untuk diimplementasikan pada sistem deteksi *fraud* operasional.
4. Metode *undersampling* meskipun efisien secara waktu komputasi, tidak layak diterapkan secara praktis karena menghasilkan *precision* yang sangat rendah akibat masifnya jumlah alarm palsu (*false positive*).
5. Evaluasi model deteksi *fraud* wajib menggunakan kombinasi metrik AUPRC, *Precision*, dan *Recall*, serta tidak boleh hanya mengandalkan akurasi atau ROC-AUC semata.