Penerapan Algoritma PrefixSpan untuk Penggalian Pola Pembelian Berurutan pada Dataset Online Retail

Aziz Rahmad Arifin 5054251002

Rekayasa Kecerdasan Artifisial, Institut Teknologi Sepuluh Nopember

***Abstrak*—Analisis pola pembelian berurutan membantu pengecer memahami produk yang cenderung dibeli pelanggan pada kunjungan berikutnya. Percobaan ini menerapkan algoritma *PrefixSpan* pada dataset Online Retail dari UCI *Machine Learning Repository* yang berisi 541.909 baris transaksi. Setelah pembersihan diperoleh 396.370 baris, 18.405 invoice, dan 4.335 pelanggan; setiap pelanggan disusun menjadi satu *sequence* berisi itemset (invoice) yang urut waktu. Empat nilai minimum *support* diuji (0,01; 0,02; 0,03; 0,05) dan nilai 0,03 dipilih karena menghasilkan 944 pola, 289 di antaranya pola berurutan, sedangkan nilai 0,01 menghasilkan 34.674 pola. Tiga pola dengan *support* tertinggi adalah pembelian ulang White Hanging Heart T-Light Holder (*support* 0,0934; *confidence* 0,4731), Regency Cakestand 3 Tier (0,0761; 0,3746), dan Jumbo Bag Red Retrospot (0,0720; 0,4913), dengan *lift* 1,84–3,35. Pola antarproduk berbeda yang terkuat berasal dari seri Lunch Bag (*lift* hingga 3,77). Hasil ini menunjukkan asosiasi berurutan antarproduk, bukan hubungan sebab-akibat, dan dapat menjadi dasar awal untuk pengingat pembelian ulang dan rekomendasi produk berikutnya.**

***Kata kunci*—*sequential pattern mining*, *PrefixSpan*, Online Retail, *support*, *confidence*, pembelian berurutan**

I. PENDAHULUAN

Sequential pattern mining adalah teknik penggalian data untuk menemukan subsequence yang sering muncul pada kumpulan sequence yang berurutan waktu [1]. Berbeda dengan *association rule mining* yang melihat produk yang dibeli bersamaan dalam satu transaksi, teknik ini memperhatikan urutan transaksi seorang pelanggan dari waktu ke waktu, misalnya "pelanggan yang membeli produk A cenderung membeli produk B pada kunjungan berikutnya". Informasi ini berguna untuk rekomendasi produk berikutnya, pengingat pembelian ulang, dan perencanaan stok.

Percobaan ini bertujuan memahami konsep *sequential pattern analysis*, menerapkan algoritma *PrefixSpan* pada dataset transaksi, serta mengevaluasi pola yang ditemukan menggunakan *support* dan *confidence*. *PrefixSpan* merupakan salah satu algoritma *sequential pattern mining* yang banyak digunakan, termasuk pada sistem rekomendasi *e-commerce* berbasis urutan pembelian [2]. Algoritma ini menggali pola dengan memproyeksikan basis data ke setiap *prefix* tanpa membangkitkan kandidat pola. Nilai *lift* ditambahkan sebagai ukuran pelengkap. Perlu dicatat bahwa percobaan ini tidak membandingkan *PrefixSpan* dengan GSP; waktu eksekusi hanya dicatat sebagai informasi, bukan sebagai dasar pemilihan algoritma.

II. METODOLOGI

A. Dataset dan Eksplorasi Data

Dataset Online Retail diambil dari UCI *Machine Learning Repository* [4] dan dibaca dari berkas Online Retail.xlsx menggunakan *pandas* di Google Colab. Dataset memiliki delapan kolom: InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, dan Country. Pengecekan *missing value* menunjukkan kolom CustomerID kosong sebesar 24,93% dan Description sebesar 0,27%, sedangkan kolom lain lengkap. Pada percobaan ini CustomerID menentukan satu *sequence*, InvoiceNo menentukan batas satu itemset, InvoiceDate menentukan urutan waktu, dan Description menjadi item yang dibeli.

B. Preprocessing Data

Baris dengan Description kosong dihapus, sedangkan Description yang tersisa dirapikan dari spasi berlebih dan diseragamkan menjadi huruf kapital. Selanjutnya invoice pembatalan (berawalan "C"), baris dengan Quantity ≤ 0, dan baris tanpa CustomerID dikeluarkan; CustomerID kemudian dikonversi menjadi bilangan bulat. Setelah keempat langkah tersebut tersisa 397.924 baris. Sebagai langkah tambahan, 1.554 baris non-produk dihapus berdasarkan StockCode (POST, D, M, DOT, CRUK, C2, BANK CHARGES, AMAZONFEE, S, B, PADS, ADJUST, dan ADJUST2) karena berupa biaya atau penyesuaian, bukan produk yang dibeli. Langkah tambahan ini berada di luar ketentuan praktikum dan dapat dimatikan melalui satu parameter di notebook.

C. Penyusunan Sequence

Data dikelompokkan berdasarkan pasangan CustomerID dan InvoiceNo. Seluruh produk pada satu invoice digabung menjadi satu itemset (produk yang sama dalam satu invoice dihitung sekali), dengan waktu invoice diambil dari InvoiceDate paling awal. Itemset milik satu pelanggan lalu diurutkan menurut InvoiceDate sehingga membentuk satu *sequence*. Seluruh *sequence* disimpan sebagai daftar bertingkat (*list of list*), yaitu daftar pelanggan yang masing-masing berisi daftar itemset yang urut waktu.

D. Implementasi Algoritma PrefixSpan

Pustaka *prefixspan* hanya menerima *sequence* dengan satu item per elemen, sehingga batas antar-invoice hilang dan item dalam satu invoice dapat terhitung sebagai urutan. Karena itu *PrefixSpan* diimplementasikan langsung pada *sequence* berisi itemset. Pola berbentuk ⟨a → b → c⟩, yaitu a dibeli pada suatu invoice, b pada invoice yang lebih akhir, dan c pada invoice yang lebih akhir lagi. Pada proyeksi basis data, setelah suatu item cocok pada invoice ke-k, pencarian item berikutnya dimulai dari invoice ke-(k+1) dengan pencocokan paling awal. Panjang pola dibatasi maksimum tiga item agar waktu komputasi terkendali. *Minimum support* bersifat relatif terhadap jumlah pelanggan dan diuji pada empat nilai, yaitu 0,01 (titik awal sesuai ketentuan), 0,02, 0,03, dan 0,05.

E. Evaluasi Pola Berurutan

Misalkan N adalah jumlah pelanggan (jumlah *sequence*), P = $\langle a_1 \rightarrow \ldots \rightarrow a_n \rangle$ adalah pola berurutan, dan σ(P) adalah jumlah pelanggan yang *sequence*-nya memuat P sebagai *subsequence*. *Support* menyatakan proporsi pelanggan yang memiliki pola tersebut:

$$s(P) = \frac{\sigma(P)}{N} \tag{1}$$

Untuk pola dengan n ≥ 2, misalkan Q = $\langle a_1 \rightarrow \ldots \rightarrow a_{n-1} \rangle$ adalah *prefix* dari P, sehingga terbentuk aturan berurutan (*sequential rule*) Q ⇒ a_n [3]. *Confidence* menyatakan peluang pelanggan yang telah memiliki *prefix* Q akan kemudian membeli item terakhir a_n:

$$\text{conf}(Q \Rightarrow a_n) = \frac{s(P)}{s(Q)} \tag{2}$$

Lift membandingkan *confidence* dengan *support* item terakhir:

$$\text{lift}(Q \Rightarrow a_n) = \frac{\text{conf}(Q \Rightarrow a_n)}{s\langle a_n \rangle} \tag{3}$$

Nilai *lift* di atas 1 menunjukkan urutan yang lebih sering terjadi daripada jika pembelian kedua item saling bebas. Pola yang dievaluasi adalah pola dengan panjang minimal dua. Tiga pola terbaik dipilih berdasarkan *support* tertinggi sesuai ketentuan

, dan sebagai pelengkap ditampilkan pula tiga pola dengan item berbeda yang *support*-nya tertinggi.

III. HASIL DAN PEMBAHASAN

A. Hasil Eksplorasi dan Preprocessing

Tabel I merangkum kondisi data sebelum dan sesudah pembersihan. Jumlah baris turun dari 541.909 menjadi 396.370 (selisih 145.539), jumlah invoice dari 25.900 menjadi 18.405, dan jumlah pelanggan dari 4.372 menjadi 4.335. Penurunan baris terutama berasal dari baris tanpa CustomerID (24,93% dari data awal), sedangkan kontribusi tiap kriteria pembersihan lain tidak dipisahkan dalam keluaran notebook. Pemeriksaan setelah pembersihan menunjukkan tidak ada lagi Description kosong, CustomerID kosong, invoice berawalan "C", maupun Quantity ≤ 0.

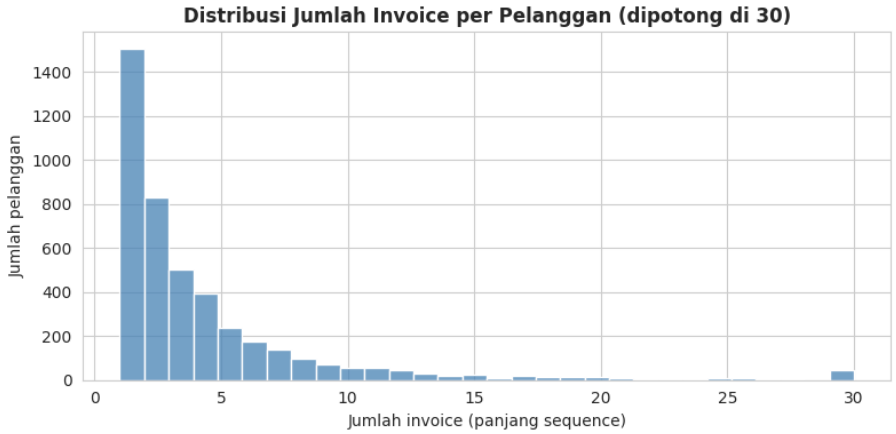
TABEL I — RINGKASAN DATA SEBELUM DAN SESUDAH PEMBERSIHAN

Keterangan	**Sebelum**	**Sesudah**
Jumlah baris	541.909	396.370
Jumlah invoice	25.900	18.405
Jumlah pelanggan	4.372	4.335
Missing value Description	0,27%	0
Missing value CustomerID	24,93%	0
Kolom yang digunakan	8	4 (CustomerID, InvoiceNo, InvoiceDate, Description)

Hanya 37 pelanggan yang hilang karena pembersihan, sehingga hampir seluruh pelanggan tetap terwakili. Daftar kode non-produk disusun berdasarkan StockCode yang dikenali, sehingga entri non-produk lain yang tidak masuk daftar masih mungkin tersisa dan menjadi keterbatasan percobaan.

B. Hasil Penyusunan Sequence

Penyusunan menghasilkan 4.335 *sequence* (satu per pelanggan) dengan total 18.405 itemset. Rata-rata satu pelanggan memiliki 4,25 invoice (simpangan baku 7,64), dengan median 2, kuartil pertama 1, kuartil ketiga 5, dan maksimum 206 invoice. Sebanyak 1.506 pelanggan (34,7%) hanya memiliki satu invoice sehingga hanya dapat menyumbang pola panjang satu. Gambar 1 memperlihatkan distribusi yang sangat miring ke kanan: sebagian besar pelanggan berbelanja sedikit kali, sedangkan sebagian kecil berbelanja sangat sering.



Gambar 1. Distribusi jumlah invoice per pelanggan (nilai di atas 30 digabung pada 30).

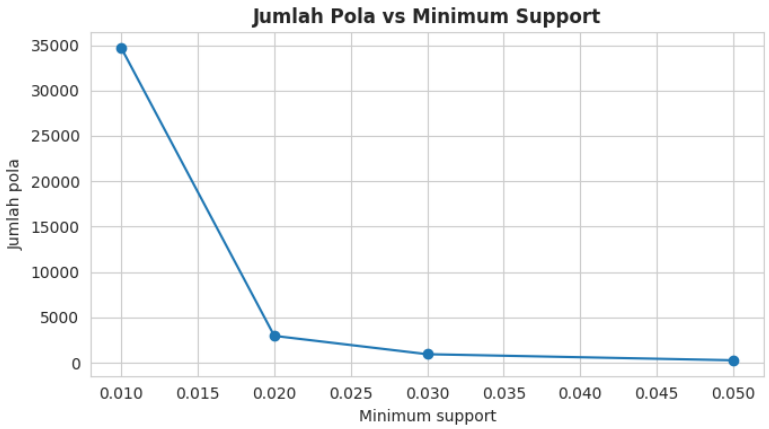
C. Hasil Pemilihan Minimum Support

Tabel II membandingkan keempat nilai *minimum support*. Pada 0,01 (minimal 44 pelanggan) ditemukan 34.674 pola dengan waktu eksekusi sekitar 76 detik, sebagian besar berupa pola panjang dua dan tiga. Jumlah ini turun tajam menjadi 2.965 pada 0,02, 944 pada 0,03, dan 273 pada 0,05. Pola panjang tiga turun dari 17.247 menjadi 416, 9, dan 1, sedangkan pola panjang dua turun dari 15.666 menjadi 1.505,

280, dan 8. Waktu eksekusi merupakan satu kali pengukuran di Google Colab sehingga hanya bersifat indikatif.

TABEL II — PERBANDINGAN NILAI MINIMUM SUPPORT

Min. *support*	Min. pelanggan	Total pola	Panjang 1	Panjang 2	Panjang 3	Waktu (dtk)
0,01	44	34.674	1.761	15.666	17.247	76,6
0,02	87	2.965	1.044	1.505	416	18,8
0,03	**131**	**944**	**655**	**280**	**9**	**9,9**
0,05	217	273	264	8	1	3,4

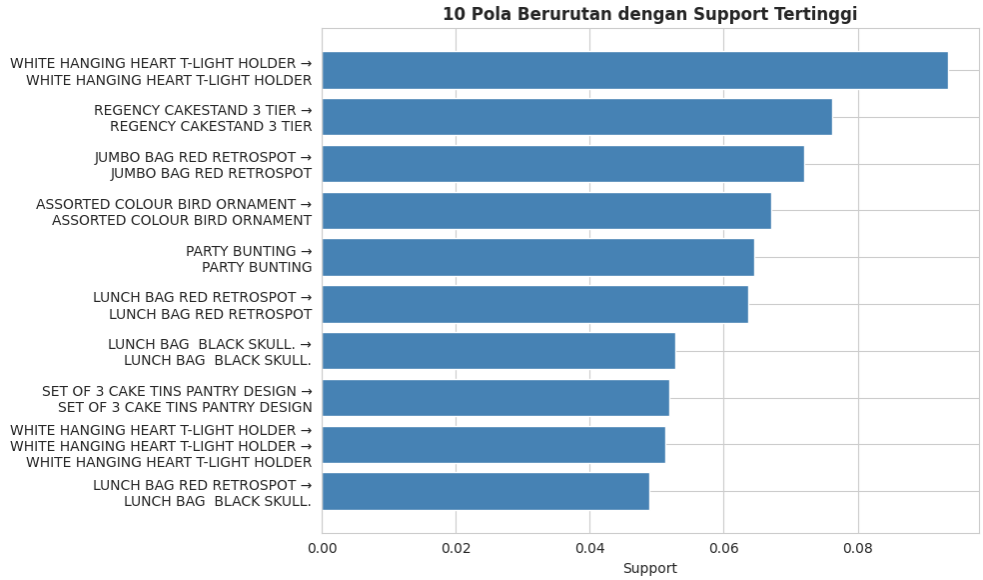


Gambar 2. Jumlah pola terhadap *minimum support*.

Nilai 0,03 dipilih sebagai parameter akhir. Pada 0,01 dan 0,02, jumlah pola (34.674 dan 2.965) terlalu banyak untuk dianalisis satu per satu. Pada 0,05, pola berurutan panjang dua tinggal 8 buah sehingga variasi urutan antarproduk hampir tidak terlihat. Pada 0,03 diperoleh 944 pola yang terdiri atas 655 pola panjang satu, 280 pola panjang dua, dan 9 pola panjang tiga. Dengan demikian 289 pola berurutan tersedia untuk dianalisis, termasuk pola panjang tiga. Pemilihan ini merupakan kompromi antara jumlah pola dan keberagaman pola, bukan hasil satu kriteria tunggal.

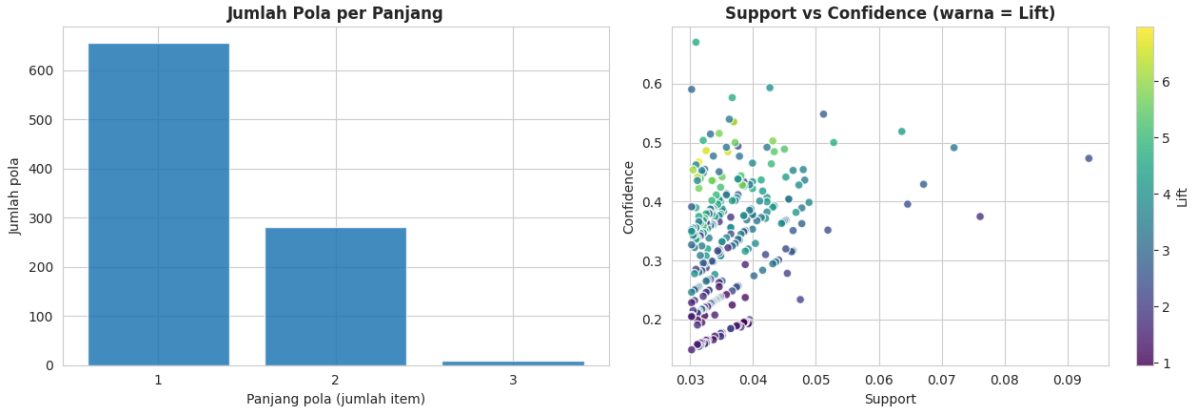
D. Hasil Pola Berurutan

Dari 289 pola berurutan pada parameter terpilih, 67 pola berupa pembelian ulang produk yang sama (A → A) dan 222 pola berupa urutan produk berbeda. Gambar 3 menampilkan sepuluh pola dengan *support* tertinggi. Sembilan di antaranya adalah pembelian ulang produk yang sama (delapan pola A → A dan satu pola A → A → A), dan pola dengan produk berbeda pertama baru muncul di peringkat sepuluh, yaitu Lunch Bag Red Retrospot → Lunch Bag Black Skull.



Gambar 3. Sepuluh pola berurutan dengan *support* tertinggi.

Panel kiri Gambar 4 memperlihatkan jumlah pola per panjang pada parameter terpilih, sedangkan panel kanan memperlihatkan sebaran *support* dan *confidence* seluruh pola berurutan dengan warna yang menunjukkan *lift*. Berdasarkan pembacaan grafik, sebagian besar pola memiliki *support* antara 0,03 dan 0,05, *confidence* sekitar 0,15 hingga 0,67, dan *lift* sekitar 1 hingga 7. Pola dengan *support* terbesar (sekitar 0,09) memiliki *lift* yang relatif rendah, sedangkan pola ber-*lift* tinggi berada pada *support* yang lebih rendah di sekitar 0,03–0,04. Hal ini menunjukkan bahwa frekuensi yang tinggi tidak otomatis disertai kekuatan asosiasi yang tinggi.



Gambar 4. Jumlah pola per panjang (kiri) serta sebaran *support* dan *confidence* pola berurutan dengan warna menunjukkan *lift* (kanan).

E. Analisis Tiga Pola dengan Support Tertinggi

Tabel III menyajikan tiga pola berurutan dengan *support* tertinggi. Ketiganya berupa pembelian ulang produk yang sama. Hasil *PrefixSpan* untuk pola pertama telah diverifikasi dengan penghitungan manual (brute force) dan cocok, yaitu 405 pelanggan.

TABEL III — TIGA POLA BERURUTAN DENGAN SUPPORT TERTINGGI (MIN. SUPPORT 0,03)

No.	Pola	Pelanggan	*Support*	*Confidence*	*Lift*
1	White Hanging Heart T-Light Holder → White Hanging Heart T-Light Holder	405	0,0934	0,4731	2,40
2	Regency Cakestand 3 Tier → Regency Cakestand 3 Tier	330	0,0761	0,3746	1,84
3	Jumbo Bag Red Retrospot → Jumbo Bag Red Retrospot	312	0,0720	0,4913	3,35

Pola 1 menunjukkan bahwa 9,3% pelanggan (405 dari 4.335) membeli White Hanging Heart T-Light Holder pada suatu invoice dan membelinya lagi pada invoice yang lebih akhir. Dari pelanggan yang pernah membelinya, 47,3% membelinya lagi, dengan *lift* 2,40. Pola 2 (Regency Cakestand 3 Tier) memiliki *confidence* terendah di antara ketiganya (37,5%) dan *lift* 1,84; dugaan yang masuk akal adalah produk ini tahan lama sehingga jarang perlu dibeli berulang oleh pelanggan ritel, tetapi dugaan tersebut tidak diuji pada data. Pola 3 (Jumbo Bag Red Retrospot) memiliki *confidence* 49,1% dan *lift* 3,35, tertinggi di antara ketiganya, yang berarti pembelian ulangnya paling jauh melampaui yang diharapkan jika pembelian saling bebas. Pola panjang tiga dengan *support* tertinggi adalah pembelian White Hanging Heart T-Light Holder tiga kali berturut-turut (222 pelanggan, *support* 0,0512, *confidence* 0,5481, *lift* 2,78): 54,8% pelanggan yang telah dua kali membeli produk ini membelinya lagi untuk ketiga kalinya.

Karena tiga pola teratas semuanya berupa pembelian ulang, Tabel IV melengkapinya dengan tiga pola antarproduk berbeda yang *support*-nya tertinggi. Ketiganya berasal dari seri Lunch Bag dengan *lift* 3,56–3,77, lebih tinggi daripada ketiga pola pembelian ulang pada Tabel III (1,84–3,35). Pasangan Red Retrospot dan Black Skull muncul pada kedua arah urutan (208 dan 212 pelanggan), sehingga pelanggan membeli keduanya tanpa urutan yang tetap.

TABEL IV — TIGA POLA ANTARPRODUK BERBEDA DENGAN SUPPORT TERTINGGI

No.	Pola	Pelanggan	*Support*	*Confidence*	*Lift*
1	Lunch Bag Red Retrospot → Lunch Bag Black Skull	212	0,0489	0,3985	3,77
2	Lunch Bag Cars Blue → Lunch Bag Red Retrospot	209	0,0482	0,4363	3,56
3	Lunch Bag Black Skull → Lunch Bag Red Retrospot	208	0,0480	0,4541	3,70

Dalam konteks ritel, pola pembelian ulang mendukung pengingat pembelian ulang atau penawaran restock untuk produk andalan seperti White Hanging Heart T-Light Holder dan Jumbo Bag Red Retrospot. Pola antarproduk dalam seri Lunch Bag mendukung rekomendasi motif lain dari seri yang sama setelah pelanggan membeli satu motif. Beberapa hal perlu diperhatikan dalam membaca hasil ini. Pertama, *confidence* dihitung terhadap invoice mana pun yang lebih akhir dan tidak dibatasi selang waktu, sehingga pembelian ulang bisa terjadi berbulan-bulan kemudian. Kedua, menurut deskripsi dataset banyak pelanggan toko adalah pedagang grosir [4], yang dapat menjelaskan tingginya pembelian ulang. Ketiga, nilai *lift* di atas 1 hanya menunjukkan asosiasi positif, bukan hubungan sebab-akibat; efektivitas tindakan bisnis di atas perlu diuji lebih lanjut.

IV. KESIMPULAN

Percobaan ini menunjukkan bahwa *PrefixSpan* dapat diterapkan pada 4.335 *sequence* pelanggan (18.405 invoice) dataset Online Retail untuk menemukan pola pembelian berurutan. Pada *minimum support*

0,01; 0,02; 0,03; dan 0,05 ditemukan berturut-turut 34.674, 2.965, 944, dan 273 pola. Nilai 0,03 dipilih sebagai kompromi dan menghasilkan 289 pola berurutan, terdiri atas 67 pola pembelian ulang dan 222 pola antarproduk berbeda.

Tiga pola dengan *support* tertinggi adalah pembelian ulang White Hanging Heart T-Light Holder (*support* 0,0934; *confidence* 0,4731), Regency Cakestand 3 Tier (0,0761; 0,3746), dan Jumbo Bag Red Retrospot (0,0720; 0,4913), dengan *lift* 1,84–3,35. Pola antarproduk terkuat berasal dari seri Lunch Bag dengan *lift* hingga 3,77. Hasil ini dapat menjadi dasar awal untuk pengingat pembelian ulang, rekomendasi produk berikutnya, dan pengelolaan stok, dengan catatan bahwa hasilnya tidak menunjukkan hubungan sebab-akibat.

Keterbatasan percobaan meliputi: 34,7% pelanggan hanya memiliki satu invoice sehingga tidak dapat membentuk pola berurutan; panjang pola dibatasi tiga item; selang waktu antar pembelian tidak dibatasi; daftar kode non-produk disusun secara manual; data hanya mencakup satu toko dan 13 bulan; serta pemilihan parameter bersifat kompromi.

DAFTAR PUSTAKA

[1] A. Bechini, A. Bondielli, P. Dell'Oglio, and F. Marcelloni, "From basic approaches to novel challenges and applications in sequential pattern mining," *Appl. Comput. Intell.*, vol. 3, no. 1, pp. 44–78, 2023, doi: 10.3934/aci.2023004.

[2] C. I. Ezeife and H. Karlapalepu, "A survey of sequential pattern based e-commerce recommendation systems," *Algorithms*, vol. 16, no. 10, Art. no. 467, 2023, doi: 10.3390/a16100467.

[3] W. Gan, G. Huang, J. Ren, and P. S. Yu, "Guided exploration of sequential rules," *arXiv preprint* arXiv:2602.16717, Feb. 2026.

[4] D. Chen, "Online Retail," *UCI Machine Learning Repository*. [Online]. Available: https://archive.ics.uci.edu/dataset/352/online+retail (accessed Nov. 9, 2026).